

TUGAS AKHIR - EC234801

SEGMENTASI SEL PADA CITRA IMUNOHISTOKIMIA MENGUNAKAN METODE SEGMENT ANYTHING MODEL

Novriyanto Putra Satir

NRP 5024 20 1001

Dosen Pembimbing

Reza Fuad Rachmadi, S.T., M.T., Ph.D

NIP 19850403 201212 1 001

Dr. dr. Imam Susilo, Sp.PA (K)., FISC.M., MIAP

NIP 19650810 199702 1 001

Program Studi Strata 1 (S1) Teknik Komputer

Departemen Teknik Komputer

Fakultas Teknologi Elektro dan Informatika Cerdas

Institut Teknologi Sepuluh Nopember

Surabaya

2025



TUGAS AKHIR - EC234801

SEGMENTASI SEL PADA CITRA IMUNOHISTOKIMIA MENGUNAKAN METODE SEGMENT ANYTHING MODEL

Novriyanto Putra Satir

NRP 5024 20 1001

Dosen Pembimbing

Reza Fuad Rachmadi, S.T., M.T., Ph.D

NIP 19850403 201212 1 001

Dr. dr. Imam Susilo, Sp.PA (K)., FISC.M., MIAP

NIP 19650810 199702 1 001

Program Studi Strata 1 (S1) Teknik Komputer

Departemen Teknik Komputer

Fakultas Teknologi Elektro dan Informatika Cerdas

Institut Teknologi Sepuluh Nopember

Surabaya

2025

[Halaman ini sengaja dikosongkan]



FINAL PROJECT - EC234801

CELL SEGMENTATION IN IMMUNOHISTOCHEMICAL IMAGES USING THE SEGMENT ANYTHING MODEL METHOD

Novriyanto Putra Satir

NRP 5024 20 1001

Advisor

Reza Fuad Rachmadi, S.T., M.T., Ph.D

NIP 19850403 201212 1 001

Dr. dr. Imam Susilo, Sp.PA (K)., FISC.M., MIAP

NIP 19650810 199702 1 001

Undergraduate Study Program of Computer Engineering

Department of Computer Engineering

Faculty of Intelligent Electrical and Informatics Technology

Sepuluh Nopember Institute of Technology

Surabaya

2025

[Halaman ini sengaja dikosongkan]

LEMBAR PENGESAHAN

SEGMENTASI SEL PADA CITRA IMUNOHISTOKIMIA MENGGUNAKAN METODE SEGMENT ANYTHING MODEL

TUGAS AKHIR

Diajukan untuk memenuhi salah satu syarat
memperoleh gelar Sarjana Teknik pada
Program Studi S-1 Teknik Komputer
Departemen Teknik Komputer
Fakultas Teknologi Elektro dan Informatika Cerdas
Institut Teknologi Sepuluh Nopember

Oleh: **Novriyanto Putra Satir**
NRP. 5024 20 1001

Disetujui oleh Tim Penguji Tugas Akhir:

Reza Fuad Rachmadi, S.T., M.T., Ph.D
NIP: 19850403 201212 1 001

(Pembimbing I)

.....

Dr. dr. Imam Susilo, Sp.PA (K)., FISC.M., MIAP
NIP: 19650810 199702 1 001

(Pembimbing II)

.....

Arta Kusuma Hernanda, S.T., M.T.
NIP: 199620231 1 024

(Penguji I)

.....

Mochamad Hariadi, S.T., M.Sc., Ph.D.
NIP: 199691209199703 1 002

(Penguji II)

.....

Dr. Surya Sumpeno, S.T., M.Sc.
NIP: 19690613199702 1 003

(Penguji III)

.....

Mengetahui,
Kepala Departemen Teknik Komputer FTEIC - ITS

Dr. Arief Kurniawan, S.T., M.T.
NIP. 19740907200212 1 001

SURABAYA
Mei, 2025

[Halaman ini sengaja dikosongkan]

APPROVAL SHEET

CELL SEGMENTATION IN IMMUNOHISTOCHEMICAL IMAGES USING THE SEGMENT ANYTHING MODEL METHOD

FINAL PROJECT

Submitted to fulfill one of the requirements
for obtaining a degree Bachelor of Engineering at
Undergraduate Study Program of Computer Engineering
Department of Computer Engineering
Faculty of Intelligent Electrical and Informatics Technology
Sepuluh Nopember Institute of Technology

By: **Novriyanto Putra Satir**
NRP. 5024 20 1001

Approved by Final Project Examiner Team:

Reza Fuad Rachmadi, S.T., M.T., Ph.D
NIP: 19850403 201212 1 001

(Advisor I)

.....

Dr. dr. Imam Susilo, Sp.PA (K)., FISC.M., MIAP
NIP: 19650810 199702 1 001

(Co-Advisor II)

.....

Arta Kusuma Hernanda, S.T., M.T.
NIP: 199620231 1 024

(Examiner I)

.....

Mochamad Hariadi, S.T., M.Sc., Ph.D.
NIP: 199691209199703 1 002

(Examiner II)

.....

Dr. Surya Sumpeno, S.T., M.Sc.
NIP: 19690613199702 1 003

(Examiner III)

.....

Acknowledged,
Head of Computer Engineering Department FTEIC - ITS

Dr. Arief Kurniawan, S.T., M.T.
NIP. 19740907200212 1 001

SURABAYA
May, 2025

[Halaman ini sengaja dikosongkan]

PERNYATAAN ORISINALITAS

Yang bertanda tangan dibawah ini:

Nama Mahasiswa / NRP : Novriyanto Putra Satir / 5024 20 1001
Departemen : Teknik Komputer
Dosen Pembimbing / NIP : Reza Fuad Rachmadi, S.T., M.T., Ph.D / 19850403 201212
1 001

Dengan ini menyatakan bahwa Tugas Akhir dengan judul "SEGMENTASI SEL PADA CITRA IMUNOHISTOKIMIA MENGGUNAKAN METODE SEGMENT ANYTHING MODEL" adalah hasil karya sendiri, bersifat orisinal, dan ditulis dengan mengikuti kaidah penulisan ilmiah.

Bilamana di kemudian hari ditemukan ketidaksesuaian dengan pernyataan ini, maka saya bersedia menerima sanksi sesuai dengan ketentuan yang berlaku di Institut Teknologi Sepuluh Nopember.

Surabaya, May 2025

Mengetahui
Dosen Pembimbing

Mahasiswa

Reza Fuad Rachmadi, S.T., M.T., Ph.D
NIP. 19850403 201212 1 001

Novriyanto Putra Satir
NRP. 5024 20 1001

[Halaman ini sengaja dikosongkan]

STATEMENT OF ORIGINALITY

The undersigned below:

Name of student / NRP : Novriyanto Putra Satir / 5024 20 1001
Department : Computer Engineering
Advisor / NIP : Reza Fuad Rachmadi, S.T., M.T., Ph.D / 19850403 201212 1
001

Hereby declared that the Final Project with the title of "CELL SEGMENTATION IN IMMUNOHISTOCHEMICAL IMAGES USING THE SEGMENT ANYTHING MODEL METHOD" is the result of my own work, is original, and is written by following the rules of scientific writing.

If in future there is a discrepancy with this statement, then I am willing to accept sanctions in accordance with provisions that apply at Sepuluh Nopember Institute of Technology.

Surabaya, May 2025

Acknowledged
Advisor

Student

Reza Fuad Rachmadi, S.T., M.T., Ph.D
NIP. 19850403 201212 1 001

Novriyanto Putra Satir
NRP. 5024 20 1001

[Halaman ini sengaja dikosongkan]

ABSTRAK

Nama Mahasiswa : Novriyanto Putra Satir
Judul Tugas Akhir : SEGMENTASI SEL PADA CITRA IMUNOHISTOKIMIA MENGGUNAKAN METODE SEGMENT ANYTHING MODEL
Pembimbing : 1. Reza Fuad Rachmadi, S.T., M.T., Ph.D
2. Dr. dr. Imam Susilo, Sp.PA (K)., FISC.M., MIAP

Setiap sel dari tubuh kita tersusun oleh protein, dengan mengetahui jenis protein dalam sebuah sel kita dapat mengetahui apakah sel tersebut adalah sel normal atau sel yang akan berubah menjadi sel kanker. Imunohistokimia atau IHC adalah sebuah metode untuk mendeteksi antigen dalam jaringan menggunakan antibodi. Pemeriksaan IHC saat ini rata-rata masih dengan cara manual dengan menggunakan mikroskop yang dilakukan langsung oleh dokter dan memakan waktu lama serta hasil pengamatan masih sangat subjektif bergantung pada kepakaran dokter tersebut, oleh karena itu tujuan dari penelitian ini adalah untuk mengembangkan sistem segmentasi yang berguna untuk melakukan segmentasi terhadap sel pada citra IHC. Proses segmentasi tersebut akan menggunakan metode segment anything model yang diusung oleh meta dan diklaim memiliki kemampuan yang efisien dalam mengenali citra. Dengan adanya penelitian ini diharapkan dapat memberikan dampak positif pada kalangan dokter dengan cara memberikan cara yang lebih efisien dalam diagnosis klinik berdasarkan IHC.

Kata Kunci: Segmentasi, Sel, Immunohistokimia, SAM, META.

[Halaman ini sengaja dikosongkan]

ABSTRACT

Name : Novriyanto Putra Satir
Title : CELL SEGMENTATION IN IMMUNOHISTOCHEMICAL IMAGES USING
THE SEGMENT ANYTHING MODEL METHOD
Advisors : 1. Reza Fuad Rachmadi, S.T., M.T., Ph.D
2. Dr. dr. Imam Susilo, Sp.PA (K)., FISC.M., MIAP

Every cell in our body is composed of protein, by knowing the type of protein in a cell we can find out whether the cell is a normal cell or a cell that will change into a cancer cell. Immunohistochemistry or IHC is a method for detecting antigens in tissue using antibodies. IHC examinations are currently mostly still done manually using a microscope which is carried out directly by a doctor and takes a long time and the results of the observations are still very subjective depending on the expertise of the doctor, therefore the purpose of this study is to develop a segmentation system that is useful for segmenting cells in IHC images. The segmentation process will use the segment anything model method carried out by meta and is claimed to have efficient capabilities in recognizing images. With this research, it is hoped that it can have a positive impact on doctors by providing a more efficient way of clinical diagnosis based on IHC.

Keywords: Segmentation, Cells, Immunohistochemistry, SAM, META.

[Halaman ini sengaja dikosongkan]

KATA PENGANTAR

Puji dan syukur kehadiran Allah SWT yang telah memberikan hidayah, dan kekuatan-Nya serta shalawat selalu tecurah kepada Nabi Muhammad SAW atas suri tauladan dalam kehidupan ini sehingga penulis dapat menyelesaikan Tugas Akhir yang berjudul Segmentasi sel pada citra imunohistokimia dengan metode segment anything model.

Penelitian ini disusun guna sebagai persyaratan kelulusan dan perolehan gelar Sarjana pada Departemen S1 Teknik Komputer, Fakultas Teknologi dan Elektronika Cerdas, Institut Teknologi Sepuluh Nopember. Penyelesaian Tugas Akhir ini tak luput dari bantuan berbagai pihak yang penulis ingin sampaikan ucapan terimakasih yang sebesar-besarnya kepada:

1. Keluarga, Ibu, Bapak dan Saudara tercinta yang telah mendukung penulis baik secara moral, spiritual, material, serta telah menjadi salah satu alasan penulis harus menyelesaikan Tugas Akhir ini
2. Bapak Reza Fuad Rachmadi, S.T., M.T., Ph.D dan Bapak Dr. dr. Imam Susilo, Sp.PA (K)., FISC.M., MIAP selaku dosen pembimbing dalam penelitian ini
3. Bapak Prof. Dr. I Ketut Eddy Purnama, S.T., M.T. Selaku dekan Fakultas Teknologi Elektro dan Informatika Cerdas serta ketua penelitian ICH Analyzer
4. Pak Edi selaku mentor pada penelitian IHC Analyzer
5. Itqan Fikri Assagaf, Annas Sholahudin, Ariq, Reza, Haekal, Riyan Marteen, Rafi Arya Satyaji, Gilang Maulana, Farrell Rafee Sudjatmiko, serta Andri TNM yang telah mendukung dan menemani penulis dalam mengerjakan tugas akhir ini
6. Teman-teman lab B201 yang selalu memberikan bantuan kepada penulis
7. Serta berbagai pihak lain yang turut membantu penulis dalam menyelesaikan Tugas Akhir ini yang tidak dapat disebutkan satu persatu

Akhir kata, semoga Tugas Akhir ini dapat bermanfaat dalam memberikan kontribusi dalam bidang kesehatan dan bagi kampus ITS. penulis menyadari masih banyak kekurangan dalam pengerjaan dalam penyusunan Tugas Akhir ini, maka penulis memohon maaf atas kesalahan dan kekurangan dalam penyusunan Tugas Akhir ini. Kritik dan saran sangat diharapkan oleh penulis sebagai bahan perbaikan ke depannya

Surabaya, Mei 2025

Novriyanto Putra Satir

[Halaman ini sengaja dikosongkan]

DAFTAR ISI

ABSTRAK	i
ABSTRACT	iii
KATA PENGANTAR	v
DAFTAR ISI	vii
DAFTAR GAMBAR	xi
DAFTAR TABEL	xiii
1 PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Permasalahan	2
1.3 Tujuan	2
1.4 Batasan Masalah	2
1.5 Sistematika Penulisan	2
2 TINJAUAN PUSTAKA	5
2.1 Studi Literatur	5
2.2 Segmentasi Citra	5
2.2.1 Segmentasi berbasis ambang batas(Tresholding)	6
2.2.2 Segmentasi Berbasis Edge Detection	7
2.2.3 Segmentasi Berbasis Region (Region-Based Segmentation)	7
2.2.4 Segmentasi Berbasis Pembelajaran Mesin (Supervised Learning)	8
2.2.5 Segmentasi Berbasis Pembelajaran Mendalam (Deep Learning)	9
2.3 Vision Transformer	10
2.4 Imunohistokimian	11
2.5 Segment Anything Model	13
2.6 Ki67	14
2.7 Intersection over Union (IoU)	15
2.8 Deeplearning	16

2.9	Roboflow	16
2.10	Labeling	17
2.11	PyTorch	18
2.12	YOLO	19
2.13	Receiver Operating Characteristic (ROC)	19
2.14	Precision-Recall (PR) Curve	19
3	DESAIN DAN IMPLEMENTASI	21
3.1	Sumber data	22
3.2	Deskripsi Sistem	23
3.3	Pengolahan Data	23
3.3.1	Pelabelan Dataset	23
3.4	Training Model	24
3.5	Alur Program	25
3.6	Proses Segmentasi SAM	26
4	PENGUJIAN DAN ANALISIS	29
4.1	Pengujian Segment Anything model	29
4.2	Pengujian Segment Anything Model Terhadap Citra Asli	31
4.3	Kurva ROC Segment Anything Model	34
4.4	Analisis Peforma Model YOLOv8	37
4.5	Pengujian Model Deteksi Objek Yang Digabungkan Dengan Segment Anything Model	38
4.6	Pengujian Model Gabungan Terhadap Citra Asli	41
4.7	Analisis Peforma Model YOLOv8 Setelah Fine-tuning	44
4.8	Pengujian Model Gabungan Terhadap Citra Asli setelah Fine-Tuning	44
4.9	Analisis perbandingan penggunaan SAM dan YoloSAM	46
5	PENUTUP	49
5.1	Kesimpulan	49
5.2	Saran	49
	DAFTAR PUSTAKA	51
	BIOGRAFI PENULIS	53
	LAMPIRAN	55

5.3	Gambar Citra imunohistokimia Dari Kaggle	55
5.4	Gambar Citra imunohistokimia Dari Universitas Airlanga	56
5.5	Gambar pengambilan sampel dari preparat Universitas Airlanga	56
5.6	Hasil Segmentasi Citra IHC dari Universitas Airlanga Menggunakan Segment Anything Model	57
5.7	Hasil Segmentasi Citra IHC Kaggle Menggunakan Segment Anything Model .	57
5.8	Hasil Segmentasi Dengan YOLOv8 dan Segment Anything Model Setelah Fine-Tuning	58

[Halaman ini sengaja dikosongkan]

DAFTAR GAMBAR

2.1	Gambar Software Histoquest	5
2.2	Citra Segmentasi Berbasis Ambang Batas (Tresholding)	6
2.3	Citra Segmentasi Berbasis Edge Detection	7
2.4	Citra Segmentasi Berbasis Region	8
2.5	Citra Imunohistokimia tipe Ki67	12
2.6	Website Resmi Segment Anything Model	13
2.7	Citra Sebelum Segmentasi	13
2.8	Hasil Segmentasi Dari Website Resmi Segment Anything Model	14
2.9	Website Resmi Segment Anything Model	17
3.1	Alur Penelitian	21
3.2	Citra Dari <i>Kaggle</i>	22
3.3	Citra dari preparat asli	22
3.4	Detail Dataset	23
3.5	Proses Labeling	24
3.6	Alur Segmentasi	25
3.7	Alur Segmentasi SAM	26
4.1	Kurva ROC <i>Segment Anything Model</i>	34
4.2	Hasil segmentasi pada <i>segment anything model</i>	35
4.3	Hasil segmentasi menggunakan grind pada <i>segment anything model</i>	35
4.4	Kurva ROC <i>Segment Anything Model</i> dengan Grind	36
4.5	Hasil segmentasi menggunakan grind dengan nilai 280 pada <i>segment anything model</i>	36
4.6	Kurva ROC <i>Segment Anything Model</i> dengan Grind 280	37
4.7	Peforma Model YOLOv8	37
4.8	Peforma Model YOLOv8 Setelah Fine-tuning	44
5.1	Proses Pengambilan Citra	56

[Halaman ini sengaja dikosongkan]

DAFTAR TABEL

4.1	Perbandingan Gambar Asli, Hasil SAM, dan Ground Truth	29
4.2	Hasil Pengukuran True Positive, False Positive, False Negative, True Negative, dan IoU Score	30
4.3	Hasil Rata-rata True Positive, False Positive, False Negative, True Negative, dan IoU Score	31
4.4	Perbandingan Gambar Asli, Hasil SAM, dan Ground Truth	32
4.5	Data Pengukuran TP, FP, FN, TN, dan IoU Score Model SAM pada citra asli . .	33
4.6	Data Rata-rata TP, FP, FN, TN, dan IoU Score Model SAM pada citra asli . . .	33
4.7	Perbandingan Gambar Asli, Hasil YOLO+SAM, dan Ground Truth	39
4.8	Data Pengukuran TP, FP, FN, TN, dan IoU Score Model YoloSAM	40
4.9	Data Rata-rata TP, FP, FN, TN, dan IoU Score Model YoloSAM	40
4.10	Perbandingan Gambar Asli, Hasil SAM, dan Ground Truth	41
4.11	Data Pengukuran TP, FP, FN, TN, dan IoU Score Model YoloSAM pada citra asli	42
4.12	Data Rata-rata TP, FP, FN, TN, dan IoU Score Model YoloSAM pada citra asli	43
4.13	Perbandingan Gambar Asli, Hasil SAM, dan Ground Truth	45
4.14	Data Pengukuran TP, FP, FN, TN, dan IoU Score Model YoloSAM Setelah Fine-Tuning	46
4.15	Data Rata-rata TP, FP, FN, TN, dan IoU Score Model YoloSAM Setelah Fine-Tuning	46
4.16	Waktu proses segmentasi menggunakan SAM	47
4.17	Waktu proses segmentasi menggunakan YoloSAM	47
5.1	Gambar Citra imunohistokimia Dari Kaggle	55
5.2	Gambar Citra imunohistokimia Dari Universitas Airlanga	56
5.3	Hasil segmentasi citra IHC dari Universitas Airlanga Menggunakan SAM . . .	57
5.4	Hasil segmentasi citra IHC dari Kaggle Menggunakan SAM	57
5.5	Hasil segmentasi citra IHC dari Kaggle Menggunakan SAM	58

[Halaman ini sengaja dikosongkan]

BAB I

PENDAHULUAN

1.1 Latar Belakang

Setiap sel dari tubuh kita tersusun dari protein, sel muda, sel dewasa, sel normal atau sel yang berubah menjadi sel kanker mempunyai protein yang berbeda-beda, disamping bentuk selnya juga berbeda. Protein bisa ditunjukkan di membran sel, sitoplasma atau di dalam inti sel. Dengan jenis protein apa yang dimiliki oleh sel, maka jenis protein tersebut bisa digunakan untuk melakukan identifikasi jenis selnya, misalnya untuk mendeteksi sel kanker atau bukan. Dengan demikian peran dari imunohistokimia (immunohistochemistry, IHC) selain untuk mengidentifikasi sel dan melakukan klasifikasi, juga untuk menentukan jenis protein atau jenis selnya. IHC menggunakan antibodi untuk mendeteksi antigen dalam sampel jaringan tubuh manusia. Reaksi yang terjadi ditunjukkan dengan berubahnya warna (kromokin). Terdapat sel yang bereaksi rendah, sedang dan tinggi terhadap proses ini, dan ditunjukkan dengan sel yang berwarna coklat terang, coklat muda dan coklat gelap [1].

Pemeriksaan IHC menggunakan mikroskop yang akan menangkap citra dari irisan mikro jaringan organ tubuh manusia dalam beberapa lapang pandang. Pemeriksaan Imunohistokimia dilakukan dengan cara manual atau yang disebut semi-kuantitatif dimana ahli akan menghitung skor berdasar jumlah sel yang bereaksi terhadap antigen. Skor ini dapat dibagi menjadi 2 macam yaitu Proportional Score (PS) dan Intensity Score (IS). PS dihitung berdasar persentase area jaringan tubuh yang tertutupi oleh antigen. Skor 1 akan diberikan untuk jumlah sel yang tertutup 0 sampai 1 persen, dan skor 2, 3, 4 dan 5 masing-masing untuk luas dengan area sel tertutupi sebanyak, 1-10 persen, 10 - 30 persen, 30 - 66,67 persen dan lebih dari 66,67 persen. Intensity Score mempunyai nilai 1, 2, dan 3 yang masing-masing digunakan untuk menandai intensitas dengan kategori rendah, sedang dan tinggi. Skor PS dan IS untuk keseluruhan lapang pandang kemudian dijumlah untuk mendapatkan skor total (TS) atau $TS = PS + IS$.

Pemeriksaan dengan cara manual seperti ini mempunyai beberapa permasalahan yaitu pemeriksaan membutuhkan waktu lama, jumlah dokter patologi anatomi tidak banyak dan volume pemeriksaan patologi pada rumah sakit sangat tinggi. Selain itu saat ini belum ada perangkat untuk menghitung sel dan mengklasifikasikan citra imunohistokimia dan pembacaan oleh dokter patologi anatomi bersifat subjektif bergantung pada kepakaran, pengalaman dan volume gambar yang dibaca [2].

Segment Anything Model (SAM) diciptakan untuk melampaui keterbatasan dalam segmentasi citra secara tradisional yang sering kali memerlukan penyesuaian manual untuk setiap jenis citra atau antigen yang berbeda. Penerapan SAM dalam segmentasi sel pada citra imunohistokimia berpotensi meningkatkan akurasi dan objektivitas analisis sehingga mengurangi waktu yang diperlukan untuk proses tersebut. Hal ini tidak hanya penting dalam penelitian tapi juga penting dalam meningkatkan hasil diagnostic pasien dengan menyediakan informasi yang lebih tepat dan cepat untuk mengambil keputusan klinis.

1.2 Permasalahan

Berdasarkan latar belakang diatas ada beberapa rumusan masalah yang didapatkan yaitu :

1. Perangkat lunak yang sudah ada masih kurang mampu mensegmentasi sel jika inti sel tampak tidak beraturan dan warna tidak merata
2. Pemeriksaan dengan cara manual hasilnya masih terlalu subjektif bergantung pada kepakaran, pengalaman dan volume gambar yang dibaca
3. Pemeriksaan dengan cara manual memakan waktu yang cukup lama untuk mendapatkan hasil diagnosis

1.3 Tujuan

Penelitian ini bertujuan untuk membuat sistem segmentasi untuk sel positif pada citra imunohistokimia tipe Ki67 dengan menggunakan Segment Anything Model

1.4 Batasan Masalah

Untuk memfokuskan penelitian yang diangkat maka diterapkan beberapa pembatasan. Batasan - batasan masalah adalah sebagai berikut

1. Data yang digunakan untuk dataset berasal dari Kaggle dan sampel potongan imunohistokimia oleh Dr. dr. Imam Susilo, Sp.PA (K)., FISC.M., MIAP
2. Model dari segment anything model yang digunakan adalah versi pertama
3. Citra imunohistokimia yang digunakan adalah tipe Ki67
4. Hasil hanya akan mensegmentasi dan menampilkan jumlah sel aktif, tanpa menyimpulkan kondisi pasien secara keseluruhan

1.5 Sistematika Penulisan

Laporan penelitian tugas akhir ini terbagi menjadi lima, yaitu:

1. **BAB I Pendahuluan**

Bab ini berisi latar belakang yang mendasari penelitian ini dengan permasalahan tujuan, manfaat, serta batasan masalah dalam konteks penelitian ini yang dilakukan

2. **BAB II Tinjauan Pustaka**

Bab ini berisi sumber referensi yang digunakan oleh peneliti dan penelitian terdahulu dalam melakukan penelitian. Didalamnya terdapat gambar, rumus serta penjelasan yang dapat menunjang pelaksanaan penelitian ini.

3. **BAB III Desain dan Implementasi Sistem**

Bab ini berisi proses pengembangan serta implementasi dalam penelitian ini. Proses dijelaskan secara bertahap sesuai dengan alur pengembangan yang dibuat oleh penulis.

4. **BAB IV Pengujian dan Analisa**

Bab ini berisi hasil dan analisis terhadap penelitian yang dilakukan per tahapan pengembangan.

5. BAB V Penutup

Bab ini berisi kesimpulan penelitian yang telah dilakukan serta saran untuk penelitian kedepannya yang sesuai dengan topik.

[Halaman ini sengaja dikosongkan]


BAB II

TINJAUAN PUSTAKA

Demi mendukung penelitian ini, dilakukan penelusuran pengetahuan pustaka sebagai berikut

2.1 Studi Literatur

Penelitian tentang segmentasi sel pada citra *immunohistochemistry* ini sudah pernah dilakukan. Sebelum adanya *Segment Anything Model*, penelitian dilakukan dengan menggunakan perangkat lunak *HistoQuest* yang mampu mengidentifikasi inti yang diwarnai dengan *hematoxylin* dengan sempurna jika inti memiliki bentuk normal dengan warna tengah tidak pucat. Jika inti tampak tidak beraturan dengan warna tidak merata, perangkat ini akan gagal untuk mengidentifikasi sel. Beberapa jaringan juga memiliki pertumbuhan sel yang tidak merata sehingga membuat perhitungan menjadi lebih sulit bahkan jika dihitung secara manual.



Gambar 2.1: Gambar Software Histoquest

Hasil pengujian menggunakan software *HistoQuest* memiliki hasil yang kurang memuaskan juga. Dalam analisis antar pengamat, hasil keseluruhan penghitungan sel metode manual memiliki kesesuaian yang lebih baik dibandingkan metode semi otomatis (manual: 95% LoA: -28.09 hingga 69.77, semi otomatis: 95% LoA: -31.48 hingga 90.30). Tiga dari 4 subkelompok (sel *PE*, sel epitel, dan sel stroma) yang dihitung dengan metode manual menghasilkan kesesuaian yang lebih baik dibandingkan yang dihitung dengan metode semi otomatis, kecuali subkelompok *DIE* (manual: 95% LoA: -19.01 hingga 76.89, semi otomatis: 95% LoA: -9.88 hingga 73.93) [2].


2.2 Segmentasi Citra

Segmentasi citra adalah suatu proses pemisahan citra digital kedalam beberapa bagian atau wilayah untuk menyorot suatu objek tertentu dengan tujuan analisis atau perhitungan. Segmentasi sering digunakan untuk berbagai aplikasi seperti pengenalan objek, analisis citra medis dan

pemrosesan video. Segmentasi citra memiliki beberapa pendekatan yang umumnya digunakan, mencakup:

2.2.1 Segmentasi berbasis ambang batas(Thresholding)

Segmentasi berbasis ambang batas (*Thresholding*) adalah salah satu metode segmentasi citra yang paling sederhana dan banyak digunakan dalam pemrosesan citra digital. Teknik ini bekerja dengan cara memisahkan piksel-piksel dalam citra berdasarkan nilai intensitasnya. Piksel-piksel yang memiliki nilai intensitas di atas atau di bawah ambang batas yang ditentukan akan diklasifikasikan ke dalam kelompok yang berbeda, sehingga memungkinkan untuk memisahkan objek dari latar belakang. [3]



Gambar 2.2: Citra Segmentasi Berbasis Ambang Batas (Thresholding)

Terdapat dua jenis *thresholding* yang umumnya digunakan, yaitu:

1. Global Thresholding

Metode ini menggunakan satu nilai ambang batas untuk seluruh citra. Misalnya, metode *Otsu* adalah teknik *thresholding* global yang secara otomatis menentukan nilai ambang batas optimal dengan meminimalkan varians intra-kelas dari piksel-piksel yang dikelompokkan.


2. Adaptive Thresholding

Metode ini mengatasi keterbatasan *thresholding* global dengan menggunakan ambang batas yang berbeda untuk setiap bagian citra. Teknik ini berguna untuk citra dengan pencahayaan yang tidak seragam atau kontras yang bervariasi.

Kelebihan *thresholding* adalah kesederhanaan dan efisiensinya dalam komputasi, menjadikannya pilihan yang baik untuk aplikasi *real-time* dan citra dengan kontras tinggi antara objek dan latar belakang. Namun, teknik ini memiliki keterbatasan ketika diterapkan pada citra yang kompleks atau dengan pencahayaan yang tidak merata.

2.2.2 Segmentasi Berbasis Edge Detection

Segmentasi berbasis *Edge Detection* adalah metode segmentasi citra yang mendeteksi tepi-tepi dalam citra sebagai dasar untuk memisahkan objek dari latar belakang. Metode ini didasarkan pada identifikasi perubahan tajam dalam intensitas atau gradien piksel di dalam citra. *Edge detection* sangat berguna untuk memisahkan area dengan perbedaan kontras yang tinggi, seperti batas antara objek dan latar belakang, sehingga memungkinkan identifikasi kontur objek. [4]



Gambar 2.3: Citra Segmentasi Berbasis Edge Detection

Terdapat tiga teknik edge detection yang umum digunakan, yaitu:

1. Operator Sobel

Operator ini menghitung gradien intensitas citra dalam arah horizontal dan vertikal untuk mendeteksi tepi. Ini adalah metode dasar dan cepat yang sering digunakan untuk citra dengan *noise* rendah.

2. Operator Canny


Ini adalah teknik yang lebih canggih dan populer karena memiliki beberapa langkah untuk mendeteksi tepi secara lebih akurat, termasuk *smoothing* menggunakan filter *Gaussian*, menghitung gradien, dan melakukan *non-maximum suppression* untuk menyingkirkan tepi yang lemah. Metode ini juga melibatkan *thresholding* untuk menjaga hanya tepi-tepi yang signifikan.

3. Operator Laplacian

Teknik ini menggunakan turunan kedua dari intensitas untuk mendeteksi area dengan perubahan tajam. Namun, metode ini cenderung lebih sensitif terhadap *noise*, sehingga biasanya diterapkan bersama filter *smoothing* seperti *Gaussian*.

2.2.3 Segmentasi Berbasis Region (Region-Based Segmentation)

Segmentasi berbasis *Region* (*Region-Based Segmentation*) adalah metode segmentasi citra yang memisahkan citra berdasarkan wilayah yang memiliki kemiripan karakteristik tertentu, seperti intensitas warna, tekstur, atau fitur lainnya. Berbeda dengan metode berbasis tepi yang berfokus pada deteksi perbatasan antara objek, metode ini berfokus pada pengelompokan piksel yang berdekatan dengan properti yang serupa. [5]



Gambar 2.4: Citra Segmentasi Berbasis Region

Ada tiga teknik yang umumnya digunakan dalam segmentasi berbasis region, meliputi:

1. **Region Growing**

Metode ini memulai dari satu atau beberapa titik awal (*seed points*) dan kemudian menambahkan piksel-piksel yang berdekatan jika memiliki kesamaan tertentu dengan titik awal tersebut. Proses ini berlanjut hingga tidak ada lagi piksel yang dapat ditambahkan ke dalam *region*. Metode ini sederhana dan efektif, tetapi hasilnya sangat dipengaruhi oleh pemilihan titik awal dan ambang batas kemiripan.

2. **Region Splitting and Merging**

Pendekatan ini membagi citra menjadi beberapa sub-*region*, biasanya dengan membagi citra menjadi kuadran. Setiap sub-*region* kemudian dievaluasi berdasarkan homogenitasnya. Jika suatu *region* tidak homogen, maka *region* tersebut dibagi lagi. Sebaliknya, jika dua *region* yang bersebelahan dianggap homogen, maka mereka dapat digabungkan. Teknik ini lebih fleksibel daripada *region growing*, namun memerlukan parameter untuk menentukan tingkat homogenitas.

3. **Watershed Segmentation**

Metode ini menganggap citra sebagai permukaan topografi, di mana intensitas piksel mewakili ketinggian. Teknik ini mengidentifikasi kontur atau "aliran" air untuk memisahkan area-area yang berbeda, mirip dengan air yang mengalir ke lembah-lembah. *Watershed segmentation* sangat efektif untuk memisahkan objek yang saling bersentuhan, namun rentan terhadap *over-segmentation* jika citra memiliki banyak *noise* atau detail.

Keunggulan metode segmentasi berbasis *region* adalah kemampuannya dalam menghasilkan segmentasi yang halus dan kontinu, terutama pada citra dengan intensitas yang seragam. Namun, metode ini bisa kurang efektif jika terdapat *noise* atau variasi pencahayaan yang signifikan.

2.2.4 Segmentasi Berbasis Pembelajaran Mesin (Supervised Learning)

Segmentasi berbasis *Pembelajaran Mesin* (*Supervised Learning*) adalah pendekatan yang menggunakan model pembelajaran yang dilatih dengan data berlabel untuk memprediksi segmentasi pada citra baru. Dalam metode ini, dataset yang digunakan berisi citra dengan label yang menunjukkan area atau objek tertentu, dan model dilatih untuk mengidentifikasi pola-

pola yang relevan berdasarkan karakteristik tersebut. Teknik ini telah banyak digunakan dalam aplikasi seperti deteksi objek, pengenalan wajah, dan segmentasi citra medis. [1]

Ada beberapa teknik umum dalam segmentasi berbasis pembelajaran mesin, yaitu:

1. **Support Vector Machine (SVM)**

SVM adalah algoritma klasifikasi yang mencari hyperplane terbaik untuk memisahkan data ke dalam kelas-kelas yang berbeda. Dalam segmentasi citra, *SVM* dapat digunakan untuk mengklasifikasikan piksel ke dalam berbagai kategori berdasarkan fitur-fitur seperti intensitas, tekstur, atau warna. *SVM* efektif untuk dataset kecil hingga menengah, namun membutuhkan pemilihan fitur yang baik untuk hasil optimal.

2. **Random Forest**

Algoritma ini adalah *ensemble learning* yang menggunakan banyak pohon keputusan untuk melakukan klasifikasi. Untuk segmentasi citra, *random forest* dapat menggabungkan berbagai fitur piksel dan tekstur untuk memprediksi kategori masing-masing piksel. Metode ini cenderung lebih robust terhadap *noise* dan variasi data dibandingkan *SVM*.

3. **Neural Networks**

Jaringan saraf buatan (*Artificial Neural Networks, ANN*) dapat digunakan untuk segmentasi dengan mempelajari hubungan kompleks antara fitur citra dan labelnya. Jaringan saraf berlapis (*multilayer perceptron*) dapat menangani data non-linear dan lebih kompleks dibandingkan metode tradisional seperti *SVM*.

4. **Conditional Random Fields (CRF)**

CRF adalah model grafis probabilistik yang mempertimbangkan hubungan antara piksel yang berdekatan untuk meningkatkan akurasi segmentasi. Teknik ini berguna untuk mempertahankan kontinuitas dan kehalusan dalam hasil segmentasi.

Segmentasi berbasis pembelajaran mesin menawarkan fleksibilitas dan kemampuan untuk belajar dari data, sehingga dapat menghasilkan segmentasi yang akurat pada citra yang kompleks. Namun, metode ini memerlukan dataset yang besar dan berlabel dengan baik serta waktu komputasi yang tinggi untuk pelatihan.

2.2.5 Segmentasi Berbasis Pembelajaran Mendalam (Deep Learning)

Segmentasi berbasis Pembelajaran Mendalam (*Deep Learning*) merupakan pendekatan modern yang menggunakan jaringan saraf dalam, terutama jaringan saraf konvolusi (*Convolutional Neural Networks/CNNs*), untuk memproses dan menganalisis citra secara otomatis. Teknik ini telah merevolusi bidang segmentasi citra karena kemampuannya untuk menangani kompleksitas visual dan variasi yang sulit diatasi oleh metode segmentasi tradisional. *Pembelajaran mendalam* sangat efektif dalam mengenali pola, bentuk, dan objek dalam citra, menjadikannya pilihan utama untuk berbagai aplikasi seperti segmentasi citra medis, pengenalan wajah, dan deteksi objek. [6]

Ada beberapa model dan teknik pembelajaran mendalam yang umum digunakan dalam segmentasi citra, yaitu:

1. **U-Net**

Model *U-Net* merupakan salah satu arsitektur *CNN* yang dirancang khusus untuk segmentasi citra, terutama dalam aplikasi medis. *U-Net* memiliki struktur encoder-decoder, di mana encoder bertugas mengekstraksi fitur dari citra input, sedangkan decoder memban-

gun kembali citra segmentasi dengan resolusi tinggi menggunakan informasi fitur tersebut. *U-Net* unggul dalam segmentasi citra resolusi tinggi dan bekerja baik bahkan dengan dataset yang terbatas.

2. Fully Convolutional Networks (FCNs)

FCNs adalah jaringan saraf konvolusi yang sepenuhnya menggunakan lapisan konvolusi, tanpa lapisan fully connected, sehingga dapat memproses citra dalam berbagai ukuran. *FCNs* sering digunakan untuk segmentasi citra karena kemampuannya untuk menghasilkan peta segmentasi dengan resolusi yang sama dengan citra input.

3. Mask R-CNN

Model ini adalah ekstensi dari *Faster R-CNN* yang tidak hanya mendeteksi objek dalam citra tetapi juga menghasilkan mask segmentasi untuk setiap objek yang terdeteksi. *Mask R-CNN* sering digunakan dalam segmentasi instance, di mana model ini tidak hanya memisahkan objek dari latar belakang tetapi juga membedakan objek-objek yang saling bertumpukan.

4. SegNet

SegNet adalah arsitektur jaringan saraf konvolusi lain yang mirip dengan *U-Net*, tetapi lebih fokus pada efisiensi komputasi. Ini menggunakan encoder dan decoder untuk menghasilkan segmentasi citra dengan mempertahankan informasi spasial yang penting melalui penggunaan pooling indices.

5. DeepLab

Model *DeepLab* menggunakan atrous convolutions (atau dilated convolutions) untuk mempertahankan resolusi fitur dan menggunakan *Conditional Random Fields (CRF)* untuk memperbaiki hasil segmentasi. *DeepLab* efektif dalam menangani segmentasi citra resolusi tinggi dan detail kecil.

Keunggulan metode segmentasi berbasis *pembelajaran mendalam* adalah kemampuannya dalam menangani kompleksitas visual secara otomatis, tanpa memerlukan desain fitur manual. Namun, metode ini memerlukan dataset yang sangat besar dan beranotasi dengan baik serta daya komputasi yang signifikan untuk melatih model.

2.3 Vision Transformer

Vision Transformer (ViT) adalah model deep learning yang menggunakan arsitektur *Transformer* untuk pemrosesan citra, berbeda dari pendekatan tradisional yang menggunakan jaringan saraf konvolusi (*Convolutional Neural Networks/CNN*). *Transformer*, yang awalnya dikembangkan untuk tugas-tugas pemrosesan bahasa alami (*NLP*) melalui model-model terkenal seperti *BERT* dan *GPT*, berhasil diadaptasi untuk tugas-tugas visual oleh *ViT*. Dalam arsitektur *ViT*, citra dibagi menjadi potongan-potongan kecil berukuran tetap (*patches*), yang kemudian direpresentasikan sebagai vektor fitur. Setiap patch diperlakukan seperti token dalam *NLP*, memungkinkan *Transformer* memanfaatkan mekanisme *self-attention* untuk menangkap hubungan global antarpatch. Pendekatan ini menggantikan operasi konvolusi lokal dalam *CNN* dengan pemrosesan berbasis konteks global, yang memberikan *ViT* kemampuan yang kuat dalam memahami struktur spasial dan semantik dalam citra. [7].

Keunggulan utama *ViT* terletak pada fleksibilitasnya dalam menangkap hubungan spasial dan global antarpatch, tanpa dibatasi oleh receptive field lokal seperti pada *CNN*. Mekanisme

self-attention pada *ViT* memungkinkan model untuk fokus pada bagian citra yang relevan dan mempertimbangkan hubungan antarbagian citra dengan lebih baik, yang sangat penting untuk tugas-tugas seperti segmentasi, klasifikasi, dan deteksi objek. Meski memiliki potensi besar, *ViT* membutuhkan dataset pelatihan yang sangat besar untuk mencapai performa optimal. Oleh karena itu, *ViT* sering digunakan bersama metode pretraining pada dataset skala besar, seperti *ImageNet*, sebelum diaplikasikan pada tugas downstream yang spesifik. [8].


Pada penelitian ini, *Vision Transformer (ViT)* memainkan peran kunci dalam arsitektur *Segment Anything Model (SAM)*. *SAM* menggunakan *ViT* sebagai backbone atau komponen inti untuk ekstraksi fitur citra dalam tugas segmentasi objek. *ViT* membantu mengidentifikasi dan memproses informasi visual pada berbagai skala, menjadikannya sangat efektif untuk segmentasi objek yang kompleks. Dengan membagi citra menjadi *patch* dan mengaplikasikan mekanisme *self-attention*, *ViT* dalam *SAM* dapat menangkap informasi kontekstual dan spasial secara efisien, baik pada skala kecil maupun besar. Hal ini memungkinkan *SAM* untuk melakukan segmentasi pada objek dengan bentuk dan ukuran yang beragam, termasuk dalam skenario dengan banyak objek atau objek yang saling bertumpukan.

Sebagai backbone, *ViT* juga mendukung generalisasi yang baik, memungkinkan *SAM* untuk menangani berbagai jenis citra tanpa pelatihan ulang untuk setiap kategori objek. Hal ini menjadikan *SAM* sebagai salah satu model segmentasi yang serbaguna dan kuat, khususnya dalam skenario *zero-shot learning*, di mana model mampu menyesuaikan diri dengan tugas baru tanpa pelatihan tambahan [9]. Dengan keunggulan tersebut, *ViT* tidak hanya merevolusi cara pemrosesan citra dilakukan tetapi juga memperluas batasan aplikasi deep learning dalam domain visual.

2.4 Imunohistokimian

Immunohistochemistry (IHC) pertama kali diperkenalkan oleh Coons pada tahun 1941 sebagai metode revolusioner untuk mendeteksi antigen spesifik dalam jaringan biologis menggunakan antibodi. Teknologi ini memanfaatkan interaksi spesifik antara antigen dan antibodi yang telah dilabeli dengan marker, memungkinkan visualisasi dan kuantifikasi antigen yang terdapat dalam jaringan. Pelabelan antibodi dengan marker berwarna, baik enzimatis maupun fluoresen, menjadi inti dari kemampuan visualisasi ini. Keunggulan *IHC* adalah kemampuannya untuk memberikan informasi spasial dan kuantitatif tentang distribusi antigen dalam konteks jaringan, sehingga memfasilitasi studi lebih lanjut dalam biologi molekuler dan diagnostik klinis [10].

Metode utama yang digunakan dalam *IHC* adalah metode enzimatis dan fluoresen. Dalam metode enzimatis, antibodi sekunder biasanya ditandai dengan enzim seperti peroksidase atau alkalin fosfatase. Ketika substrat yang sesuai diberikan, enzim mengkatalisis reaksi warna yang menghasilkan produk berwarna, yang dapat dilihat dengan mikroskop cahaya. Teknik ini sangat populer karena kemudahannya dalam pengamatan dan kestabilan produk berwarna. Di sisi lain, metode fluoresen memanfaatkan antibodi yang ditandai dengan molekul fluoresen seperti FITC atau rhodamin. Molekul fluoresen ini, ketika dieksitasi oleh cahaya dengan panjang gelombang tertentu, memancarkan fluoresensi yang memungkinkan visualisasi spesifik dan sangat sensitif. Metode fluoresen sering digunakan dalam penelitian tingkat lanjut, terutama ketika sensitivitas tinggi dan resolusi spasial diperlukan. [11]



Gambar 2.5: Citra Imunohistokimia tipe Ki67

Selain metode deteksi, perkembangan dalam teknologi *IHC* juga mencakup peningkatan sensitivitas antibodi, stabilitas reagen, dan otomatisasi proses. Perkembangan ini telah menjadikan *IHC* sebagai alat penting dalam biologi molekuler modern. Dalam konteks klinis, *IHC* banyak digunakan untuk diagnosis neoplasma, identifikasi biomarker spesifik, dan evaluasi respons terapi. Sebagai contoh, ekspresi protein Ki67 sering digunakan sebagai marker proliferasi dalam diagnosis dan prognosis berbagai jenis kanker. Teknik ini juga memainkan peran penting dalam deteksi patogen infeksius, seperti dalam kasus diagnosis tuberkulosis atau infeksi virus tertentu


Aplikasi *IHC* memiliki cakupan yang luas, tidak hanya terbatas pada diagnostik klinis tetapi juga meluas ke penelitian biomedis dan pengembangan obat. Dalam penelitian, *IHC* digunakan untuk mengevaluasi distribusi protein dalam jaringan normal maupun patologis, memberikan wawasan mendalam tentang mekanisme penyakit. Dalam pengembangan obat, *IHC* memungkinkan penilaian target obat serta pengamatan efek farmakologis pada tingkat jaringan dengan akurasi tinggi. Di era modern, kombinasi *IHC* dengan teknik lain seperti mikroskop konfokal dan analisis citra berbasis kecerdasan buatan semakin memperluas potensi penggunaannya. Pendekatan ini tidak hanya mendukung diagnostik, tetapi juga meningkatkan pengambilan keputusan terapeutik, misalnya dalam memprediksi resistensi atau sensitivitas terhadap pengobatan tertentu

Dengan perkembangan teknologi yang terus berlangsung, *IHC* telah menjadi salah satu teknik terpenting dalam kedokteran molekuler dan patologi. Hal ini menjadikan *IHC* tidak

hanya alat untuk diagnosis tetapi juga pilar utama dalam penelitian ilmiah, mendukung studi mendalam tentang biologi penyakit dan pengembangan terapi yang lebih efektif.

2.5 Segment Anything Model

SAM (Segment Anything Model) merupakan inovasi terbaru dalam pemrosesan citra dengan memanfaatkan pembelajaran mesin dan kecerdasan buatan untuk mengidentifikasi dan mensegmentasi berbagai objek dalam citra dengan akurat. Model ini dirancang untuk adaptasi dan generalisasi yang tinggi sehingga memungkinkan bekerja pada berbagai jenis citra tanpa perlu konfigurasi untuk setiap aplikasi baru.



Gambar 2.6: Website Resmi Segment Anything Model

Ketika Menggunakan *SAM* dalam analisis citra, proses yang dilakukan dimulai dari pengimputan citra ke dalam model yang telah dilatih untuk mengenali dan memisahkan berbagai objek atau entitas yang ada dalam citra tersebut. *SAM* menggunakan teknik pembelajaran mendalam (*deep learning*) untuk memahami detail citra yang memungkinkan untuk mengidentifikasi dan mengklasifikasi objek secara akurat bahkan dalam keadaan dimana citra tersebut terlihat samara tau tumpang tindih. Hasil akhir dari proses ini adalah citra dengan objek yang sudah tersegmentasi secara jelas, mudah diidentifikasi dan dianalisis lebih lanjut oleh pengguna. *Model Segment Anything* secara khusus dirancang untuk fleksibilitas tinggi, mampu menangani beragam jenis objek dalam berbagai kondisi citra, yang membuatnya sangat berguna dalam aplikasi seperti pengolahan citra medis, analisis satelit, dan lain-lain [9].



Gambar 2.7: Citra Sebelum Segmentasi



Gambar 2.8: Hasil Segmentasi Dari Website Resmi Segment Anything Model

Pada umumnya ada tiga cara untuk menggunakan *Segment Anything Model* pada website yang sudah dibuat oleh Meta, yaitu dengan menggunakan penanda, dimana pengguna harus memberikan tanda secara manual pada gambar yang akan disegmentasi. Kedua, dengan menggunakan *bounding box*, sama seperti cara pertama, cara kedua ini juga harus dilakukan secara manual oleh pengguna, dimana pengguna harus menggambar *bounding box* untuk objek yang akan disegmentasi pada gambar. Yang terakhir adalah menggunakan *command prompt* yang berupa teks. Cara ini berbeda dengan dua cara sebelumnya, dimana cara ini bisa dilakukan secara otomatis, dimana pengguna cukup mengetikkan apa yang ingin disegmentasi pada gambar. Akan tetapi, cara ketiga ini belum tersedia pada website segmentasi buatan Meta yang sudah ada.

Proses deteksi dan segmentasi dalam *SAM* dimulai dengan pemberian prompt visual pada citra. Model kemudian menginterpretasikan prompt tersebut dan menghasilkan peta segmentasi yang membedakan objek dari latar belakang. Keunggulan *SAM* terletak pada kemampuannya untuk menghasilkan segmentasi yang konsisten dan akurat meskipun prompt yang diberikan minimal atau kasar [9].

SAM memiliki berbagai aplikasi potensial di berbagai bidang seperti medis, otomotif, pengawasan, dan hiburan. Dalam bidang medis, *SAM* dapat digunakan untuk segmentasi jaringan atau organ dalam citra medis, seperti MRI atau CT scan, membantu dalam diagnosis dan perencanaan perawatan. Di industri otomotif, *SAM* bisa diterapkan untuk segmentasi objek dalam sistem pengenalan lingkungan untuk kendaraan otonom. Selain itu, dalam pengawasan, *SAM* dapat digunakan untuk segmentasi objek dalam video pengawasan, membantu dalam pemantauan dan analisis keamanan.

2.6 Ki67

Ki67 adalah penanda proliferasi sel yang banyak digunakan dalam diagnosis dan prognosis kanker. Protein ini diekspresikan di inti sel selama fase aktif dari siklus sel (G1, S, G2, dan M) dan tidak terdeteksi selama fase G0 (istirahat). Indeks Ki67 (*Ki67 labeling index*) dihitung berdasarkan persentase sel tumor yang menunjukkan pewarnaan positif terhadap Ki67, yang memberikan indikasi tentang tingkat proliferasi tumor.

Dalam kanker payudara, Ki67 sering digunakan untuk mengevaluasi agresivitas tumor. Tumor dengan indeks Ki67 yang lebih tinggi umumnya dianggap memiliki tingkat pertumbuhan

yang lebih cepat dan prognosis yang lebih buruk. Sebagai contoh, dalam tumor luminal yang bersifat hormon reseptor-positif, HER2-negatif, indeks Ki67 membantu memutuskan apakah kemoterapi harus ditambahkan pada terapi hormon. Namun, standar penilaian Ki67 masih bervariasi di seluruh laboratorium, yang dapat mempengaruhi konsistensi hasil klinis [12].

Penelitian juga menunjukkan bahwa Ki67 memiliki nilai prediktif pada berbagai jenis kanker, termasuk tumor endokrin, di mana ekspresi yang lebih tinggi dikaitkan dengan proliferasi sel yang cepat dan prognosis yang lebih buruk [13].

2.7 Intersection over Union (IoU)

Intersection over Union (IoU) adalah metrik evaluasi yang banyak digunakan dalam bidang visi komputer, khususnya dalam tugas deteksi dan segmentasi objek. *IoU* berfungsi untuk mengukur seberapa baik hasil prediksi model dalam mendeteksi atau *men-segmentasi* objek pada citra dibandingkan dengan data kebenaran dasar (*ground truth*). Metrik ini membandingkan area persilangan (*intersection*) antara area prediksi dan area kebenaran dasar dengan area gabungan (*union*) dari keduanya. Sehingga, nilai *IoU* dihitung sebagai rasio dari area persilangan terhadap area gabungan antara dua wilayah tersebut, yang memberi gambaran tentang kualitas prediksi model.

IoU adalah metrik yang sangat berguna dalam deteksi objek dan segmentasi citra. Pada tugas deteksi objek, misalnya, prediksi objek dianggap benar jika nilai *IoU* antara kotak pembatas (*bounding box*) prediksi dan kotak pembatas kebenaran dasar melebihi ambang batas tertentu (biasanya 0.5 atau lebih). Begitu juga pada tugas segmentasi, *IoU* digunakan untuk membandingkan area segmentasi objek yang diprediksi dengan area kebenaran dasar pada citra. Nilai *IoU* berkisar antara 0 dan 1, dengan 1 menunjukkan prediksi yang sempurna, dan 0 berarti tidak ada tumpang tindih antara prediksi dan kebenaran dasar. Oleh karena itu, semakin tinggi nilai *IoU*, semakin baik kualitas prediksi model [14], [15].

Persamaan Intersection Over Union (IoU)

$$IoU = \frac{\text{Area Intersection}}{\text{Area Union}} \quad (2.1)$$

Dengan rumus ini, *IoU* menghitung rasio antara area tumpang tindih (*intersection*) dari prediksi dan kebenaran dasar, dan total area yang tercakup oleh keduanya (*union*). Jika nilai *IoU* mendekati 1, maka prediksi sangat cocok dengan kebenaran dasar. Sebaliknya, jika nilai *IoU* mendekati 0, maka prediksi sangat buruk.

Namun, meskipun *IoU* adalah metrik yang sangat efektif, metrik ini memiliki beberapa keterbatasan. Salah satu kelemahannya adalah bahwa *IoU* mungkin tidak mencerminkan perbedaan kecil pada tepi objek dalam tugas segmentasi yang membutuhkan presisi tinggi. Hal ini dapat mengurangi efektivitasnya ketika objek yang terdeteksi sangat kecil atau jika terdapat ketidaksesuaian pada batas objek. Misalnya, dalam situasi di mana objek dalam citra sangat kecil, perubahan kecil pada bentuk atau ukuran objek dapat mempengaruhi perhitungan *IoU* secara signifikan, padahal mungkin saja perubahan tersebut tidak relevan secara visual. Dalam kasus ini, metrik lain seperti mean Average Precision (mAP) atau Dice Coefficient sering digunakan sebagai alternatif atau pelengkap untuk mengatasi kelemahan *IoU* dalam pengukuran segmentasi objek yang presisi tinggi [16], [17].

Untuk mengatasi keterbatasan *IoU*, banyak penelitian yang mengusulkan berbagai modi-

fikasi dan pendekatan alternatif. Sebagai contoh, Dice Similarity Coefficient (DSC) dan Jaccard Index sering digunakan sebagai metrik tambahan dalam bidang segmentasi medis dan citra mikrobiologi, karena mereka lebih sensitif terhadap ketidaksesuaian kecil pada tepi objek dan lebih baik dalam menangani data yang tidak seimbang [18]. Selain itu, metrik seperti bounding box regression loss digunakan dalam kombinasi dengan IoU untuk meningkatkan presisi model deteksi objek, khususnya ketika objek yang terdeteksi sangat kecil atau sangat dekat satu sama lain

Secara keseluruhan, IoU tetap menjadi salah satu metrik utama yang digunakan dalam evaluasi model deteksi dan segmentasi objek, namun perlu diingat bahwa pengukuran yang lebih kompleks atau tambahan metrik sering diperlukan untuk memperoleh evaluasi yang lebih akurat, terutama dalam tugas yang membutuhkan tingkat presisi tinggi.

2.8 Deeplearning

Deep learning adalah sub-bidang pembelajaran mesin yang menggunakan jaringan saraf tiruan dalam, atau *deep neural networks* (DNN), untuk memecahkan masalah yang rumit. Dibandingkan dengan pendekatan tradisional, *deep learning* memungkinkan komputer untuk secara otomatis belajar dari data besar melalui proses hierarkis, di mana setiap lapisan dalam jaringan saraf menangkap fitur yang semakin abstrak dan kompleks. Teknologi ini sangat sukses dalam berbagai bidang seperti pengenalan gambar, pemrosesan bahasa alami (*Natural Language Processing*, *NLP*), dan pengenalan suara [19].


Kemajuan dalam *deep learning* dimulai dengan terobosan jaringan saraf *convolutional* (CNN) untuk pengenalan gambar pada pertengahan 2010-an. Model seperti *AlexNet* yang diperkenalkan pada 2012, membuka jalan bagi pengembangan arsitektur yang lebih dalam dan lebih efisien. CNN telah menjadi standar untuk pengenalan gambar karena kemampuannya untuk menangani data visual dengan efisiensi tinggi. Di sisi lain, dalam pemrosesan bahasa alami, model jaringan saraf berulang (*Recurrent Neural Networks*, *RNN*), seperti *Long Short-Term Memory* (LSTM), serta model berbasis *transformer* seperti *BERT* dan *GPT*, telah mengubah bagaimana komputer memproses dan menghasilkan bahasa [6].

Framework seperti *TensorFlow* dan *PyTorch* sangat mendukung ekosistem *deep learning* dengan menyediakan alat yang memudahkan pembuatan dan pelatihan model *deep learning*. Selain itu, dengan adanya arsitektur seperti *Generative Adversarial Networks* (GAN) yang digunakan untuk menciptakan data sintetik, dan *Reinforcement Learning* untuk keputusan berbasis tindakan, *deep learning* semakin luas aplikasinya di bidang seperti robotika dan game.

Namun, *deep learning* tidak lepas dari tantangan, seperti kebutuhan data yang besar, daya komputasi tinggi, dan kesulitan interpretasi model yang sering disebut sebagai *black box*. Untuk menangani hal ini, pendekatan interpretabilitas dan efisiensi komputasi terus berkembang.

2.9 Roboflow

Roboflow adalah platform yang dirancang untuk mengelola, menganotasi, dan mengoptimalkan dataset *computer vision*. Platform ini mempermudah alur kerja dalam pengembangan model *machine learning*, terutama untuk tugas seperti deteksi objek, klasifikasi, dan segmentasi. Dengan Roboflow, pengguna dapat melakukan augmentasi dataset secara otomatis, mengonversi format gambar, serta mengintegrasikannya ke dalam berbagai *framework machine learning* seperti TensorFlow, PyTorch, dan YOLO.



Gambar 2.9: Website Resmi Segment Anything Model

Fitur utama Roboflow adalah kemampuannya untuk mempercepat proses persiapan dataset yang kompleks, seperti *pelabelan otomatis*, *kontrol versi*, dan *kolaborasi tim*. Roboflow juga menyediakan opsi *deployment model*, yang memungkinkan integrasi langsung ke aplikasi dunia nyata. Hal ini membuat Roboflow menjadi solusi penting dalam berbagai proyek AI di berbagai bidang seperti kesehatan, pertanian, manufaktur, dan ritel [20].

2.10 Labeling

Labeling adalah proses yang sangat penting dalam *pembelajaran mesin*, terutama dalam proyek *computer vision* yang melibatkan tugas seperti *klasifikasi objek*, *deteksi objek*, dan *segmentasi gambar*. Proses ini berfungsi untuk memberi label atau penanda pada data visual seperti gambar atau video, yang kemudian digunakan oleh model untuk mengenali pola, objek, atau fitur tertentu. *Labeling* yang akurat sangat penting untuk memastikan kualitas model yang dilatih, karena data yang diberi label dengan benar akan mengarah pada model yang lebih efektif dan efisien. Proses *labeling* yang buruk atau inkonsisten dapat menyebabkan model yang dilatih menghasilkan prediksi yang tidak akurat atau bahkan gagal untuk mengenali objek secara benar.

Pada umumnya, ada beberapa pendekatan yang digunakan dalam melakukan *labeling* data dalam tugas-tugas *computer vision*. Salah satu pendekatan adalah *pelabelan manual*, di mana manusia menandai objek atau area yang relevan dalam gambar. Pendekatan manual ini memastikan tingkat presisi yang sangat tinggi, karena manusia dapat secara langsung memahami konteks gambar dan memberikan label yang sangat relevan. Namun, *pelabelan manual* sering kali memakan waktu dan sangat bergantung pada tenaga kerja manusia, yang dapat menjadi terbatas dalam skala besar.

Untuk mengatasi keterbatasan ini, metode *semi-otomatis* dan *otomatis* dapat digunakan. Dalam pendekatan *semi-otomatis*, algoritma atau model *pembelajaran mesin* digunakan untuk memberikan prediksi awal mengenai label atau objek dalam gambar, dan kemudian manusia

melakukan koreksi atau verifikasi terhadap label tersebut. Metode ini memberikan keseimbangan antara akurasi dan efisiensi waktu, karena algoritma dapat menangani bagian-bagian tertentu dari data dengan baik, namun pengawasan manusia tetap diperlukan untuk memastikan akurasi. Misalnya, alat seperti *Roboflow* memungkinkan pengguna untuk mengimpor gambar dan memanfaatkan algoritma untuk melakukan *pelabelan otomatis*, kemudian memvalidasi dan mengedit label jika diperlukan.

Sedangkan pada *pelabelan otomatis*, algoritma atau model *machine learning* yang telah dilatih sebelumnya, seperti model berbasis *deteksi objek* (contohnya, *YOLO* atau *Faster R-CNN*), digunakan untuk menandai objek dalam gambar secara langsung tanpa campur tangan manusia. Meskipun metode ini dapat menghemat banyak waktu, akurasi *pelabelan* dapat bervariasi tergantung pada kualitas model dan data pelatihan yang digunakan.

Teknik *pelabelan* juga dapat bervariasi tergantung pada jenis tugas dalam *computer vision*. Dalam *segmentasi citra*, di mana tujuan utamanya adalah untuk mengklasifikasikan setiap piksel dalam gambar, diperlukan *pelabelan piksel demi piksel*, yang mengharuskan setiap bagian dari gambar diberi label yang sesuai dengan objek atau kelas yang relevan. Ini dapat dilakukan dengan alat seperti *Labelme* atau *Mask R-CNN*, yang memungkinkan *pelabelan objek* dengan presisi tinggi pada tingkat piksel. Sementara dalam *deteksi objek*, *pelabelan* dilakukan dengan menggambar kotak pembatas (*bounding boxes*) di sekitar objek yang relevan dalam gambar. Model *deteksi objek* kemudian dilatih untuk mengenali objek tersebut berdasarkan kotak pembatas yang telah diberi label.

Selain itu, dengan kemajuan dalam *deep learning* dan model berbasis *transformer*, teknik *pelabelan* juga mengalami perkembangan. Model-model seperti *Segment Anything Model (SAM)* yang menggunakan arsitektur *Vision Transformer (ViT)* untuk *segmentasi objek* dapat digunakan dalam proses *pelabelan* yang lebih otomatis dan lebih akurat, memanfaatkan keunggulan pengolahan citra yang lebih mendalam. Meskipun demikian, pengawasan manusia tetap diperlukan dalam banyak kasus untuk memastikan kualitas dan akurasi *pelabelan*, terutama dalam aplikasi medis atau situasi yang sangat spesifik.

Secara keseluruhan, *pelabelan* adalah proses yang mempengaruhi kinerja model *pembelajaran mesin* secara signifikan. Dengan kemajuan dalam alat *pelabelan otomatis* dan *semi-otomatis*, serta teknik yang lebih canggih seperti penggunaan *deep learning* dan *Vision Transformers*, proses ini semakin cepat dan lebih efisien, namun tetap memerlukan perhatian terhadap kualitas data agar model yang dilatih dapat menghasilkan prediksi yang optimal [21]–[23].

2.11 PyTorch

PyTorch adalah pustaka *pembelajaran mesin (machine learning) open-source* yang dikembangkan oleh *Facebook's AI Research Lab (FAIR)*. *PyTorch* terkenal karena fleksibilitasnya dan penggunaannya yang luas dalam penelitian serta pengembangan model *pembelajaran mendalam (deep learning)*. Salah satu fitur utama *PyTorch* adalah penggunaan *graf komputasi dinamis*, yang mempermudah proses debugging dan pengembangan model, dibandingkan dengan pustaka lain seperti *TensorFlow* yang menggunakan *graf komputasi statis*.

PyTorch mendukung berbagai tugas *pembelajaran mesin*, termasuk *pembelajaran terawasi (supervised learning)* dan *pembelajaran tanpa pengawasan (unsupervised learning)*. Selain itu, *PyTorch* memiliki integrasi yang kuat dengan berbagai pustaka lainnya seperti *TorchVision*, yang menyediakan *dataset* dan transformasi khusus untuk tugas *computer vision*. Fleksibil-

itas ini membuat *PyTorch* menjadi pilihan populer di kalangan peneliti dan pengembang untuk proyek-proyek seperti *pengenalan gambar*, *pemrosesan bahasa alami (NLP)*, dan bahkan proyek *robotika*.

Dengan dokumentasi yang baik dan dukungan komunitas yang kuat, *PyTorch* terus berkembang, memperkenalkan fitur-fitur baru seperti *TorchScript*, yang memungkinkan konversi model *PyTorch* menjadi format yang lebih efisien untuk *deployment* [24].

2.12 YOLO

YOLO (You Only Look Once) adalah model *deep learning* berbasis *jaringan saraf konvolusi (CNN)* yang dikembangkan untuk *deteksi objek* secara real-time. Berbeda dengan metode *deteksi objek* tradisional yang menggunakan pendekatan berbasis region (seperti *R-CNN*), *YOLO* menggunakan pendekatan *end-to-end* yang memungkinkan model untuk melihat keseluruhan citra hanya sekali dan mendeteksi objek dalam satu tahap, sehingga membuatnya sangat cepat dan efisien.

Yolo memiliki banyak versi dengan berbagai keunggulan akan tetapi versi yang digunakan pada penelitian ini adalah YOLOv8 yang digunakan untuk *training* model objek deteksi yang nantinya memiliki *output* berupa koordinat *bounding box* yang nantinya akan digunakan sebagai input *Segment Anything Model*

2.13 Receiver Operating Characteristic (ROC)

Receiver Operating Characteristic (ROC) adalah kurva yang digunakan untuk mengevaluasi performa model *klasifikasi biner* dengan memplot hubungan antara *True Positive Rate (TPR)* (*sensitivitas*) dan *False Positive Rate (FPR)* pada berbagai *threshold*. ROC membantu mengukur kemampuan model untuk memisahkan kelas positif dan negatif. Nilai TPR dihitung dengan membandingkan jumlah *True Positives (TP)* dengan total jumlah kasus positif, sementara FPR dihitung dengan membandingkan jumlah *False Positives (FP)* dengan total jumlah kasus negatif. Selain itu, evaluasi ROC sering dilengkapi dengan *Area Under the Curve (AUC)*, yang memberikan nilai numerik untuk mengevaluasi performa model secara keseluruhan. Nilai AUC berkisar dari 0 hingga 1, di mana nilai yang lebih tinggi menunjukkan performa yang lebih baik. ROC-AUC sangat efektif dalam mengevaluasi model pada dataset dengan distribusi kelas yang seimbang, namun kurang ideal untuk dataset dengan ketidakseimbangan kelas yang signifikan, karena metrik FPR menjadi kurang representatif dalam situasi tersebut [25].

Persamaan untuk TPR

$$TPR = \frac{TP}{TP + FN} \quad (2.2)$$

Persamaan untuk FPR

$$FPR = \frac{FP}{FP + TN} \quad (2.3)$$

2.14 Precision-Recall (PR) Curve

Precision-Recall (PR) Curve adalah metrik evaluasi yang lebih relevan untuk dataset dengan ketidakseimbangan kelas tinggi. PR curve memplot hubungan antara *Precision* dan *Recall*. *Precision* mengukur kemampuan model untuk menghindari prediksi positif yang salah, sementara *recall* mengukur sejauh mana model dapat mendeteksi semua kelas positif. *Preci-*

sion dihitung sebagai rasio antara jumlah *True Positives* (*TP*) dengan total prediksi positif (*TP* + *FP*), sedangkan *recall* dihitung sebagai rasio antara *TP* dengan total kasus positif (*TP* + *FN*). PR curve sering digunakan bersama dengan *Average Precision* (*AP*), yaitu area di bawah kurva yang memberikan evaluasi kuantitatif performa model dalam menyeimbangkan *precision* dan *recall*. PR curve sangat bermanfaat pada tugas yang memprioritaskan identifikasi kelas positif, seperti diagnosis medis atau deteksi anomali, namun kurang efektif untuk mengevaluasi performa pada kelas negatif atau pada dataset dengan distribusi kelas yang seimbang [26].

Permasalahan untuk Recall

$$\text{Recall} = \frac{TP}{TP + FN} \quad (2.4)$$


Persamaan untuk Precision

$$\text{Precision} = \frac{TP}{TP + FP} \quad (2.5)$$

BAB III

DESAIN DAN IMPLEMENTASI


Penelitian ini dilaksanakan sesuai dengan desain blok diagram yang telah disusun pada gambar 3.1, desain dan implementasi diuraikan dengan perawalan perolehan dataset *Imunohistokimia*, pengolahan data, Pengujian model *Segment Anything Model* dan dilakukan pengembangan model Yolo serta dilakukan analisis hasil pengujian pada model terkait menggunakan data citra *imunohistokimia* yang berasal dari *Kaggle* dan citra langsung yang diambil dari Universitas Airlangga.



Gambar 3.1: Alur Penelitian


3.1 Sumber data

Data yang digunakan pada penelitian ini adalah citra *Imunohistokimia* yang berasal dari data publik yang ada pada platform kaggle, data tersebut berisi hasil scan citra imunohistokimiation dari berbagai pasien dan berbagai region. Adapun tipe citra yang ada pada data tersebut adalah Ki67, ER, Her2 dan PR.



Gambar 3.2: Citra Dari *Kaggle*


Selain itu ada juga data citra Imunohistokimia yang diambil langsung melalui preparat dengan mikroskop yang diperoleh dari Universitas Airlangga melalui pak Edi.



Gambar 3.3: Citra dari preparat asli

3.2 Deskripsi Sistem

Pada penelitian ini sistem akan dibuat dengan menggabungkan dua jenis model yang berbeda yaitu model segmentasi menggunakan Segment Anything Model dan model untuk objek deteksi menggunakan Yolo versi 8. Adapun prosesnya akan melibatkan platform Roboflow untuk melakukan labeling pada data yang didapat, untuk model yang akan dibuat peneliti menggunakan total 1041 citra imunohistokimia dengan detail 933 citra sebagai data training, 72 citra sebagai validasi dan 36 citra sebagai data tes, data yang digunakan untuk training sudah diterapkan augmentasi dari platform Roboflow dengan tipe 90 derajat rotate clockwise, counter-clockwise, dan upside down.




Gambar 3.4: Detail Dataset

3.3 Pengolahan Data

Data citra imunohistokimia yang diperoleh perlu melalui beberapa tahapan agar dapat diproses untuk segmentasi, berikut adalah tahapan yang dilalui:

3.3.1 Pelabelan Dataset

Tahapan pertama pada penelitian ini adalah pelabelan pada setiap citra imunohistokimia yang ada dalam dataset, tiap citra Imunohistokimia yang memiliki sel aktif akan diberi label *Active-cell*



Gambar 3.5: Proses Labeling

Pada gambar 3.3 diatas dapat dilihat bahwa sel aktif yang ditandai dengan warna coklat akan diberikan label *Active-cell*, akan tetapi ada beberapa corak coklat yang bukan sel aktif melainkan hanya sebuah noda darah.

3.4 Training Model

Dataset yang sudah diberikan label selanjutnya akan ditraining. Pada penelitian ini akan digunakan model *YOLOv8* dengan pengaturan gambar yang dimasukkan ke model diubah ke ukuran 640x640 piksel. Model ditraining dengan *batch size* sebesar 16 dan proses training diatur untuk berlangsung sebanyak 50 *epoch*. Hasil dari training ini akan menghasilkan model untuk deteksi objek yang nantinya akan menghasilkan koordinat *bounding box* yang akan dijadikan sebagai input untuk model *Segment Anything Model*.

Tipe *YOLOv8* yang digunakan pada penelitian ini adalah tipe *nano*. Tipe ini digunakan karena dirancang dengan ukuran model yang lebih kecil dan lebih ringan. Dalam training, *YOLOv8 nano* mempertahankan efisiensi dan kecepatan yang optimal meskipun dengan kapasitas model yang lebih kecil. Secara teknis, *YOLOv8 Nano* menggunakan arsitektur yang lebih sederhana dan memiliki lebih sedikit parameter dibandingkan model lainnya. Ini berarti *Nano* mengorbankan sebagian kecil dari akurasi yang dimiliki oleh model yang lebih besar, namun dengan kompensasi kecepatan dan konsumsi memori yang lebih rendah. Pada proses training, *Nano* tetap melalui tahapan *backbone*, *neck*, dan *head* untuk melakukan deteksi objek. Namun, jumlah lapisan dan kompleksitas komputasi dikurangi, sehingga proses training dapat berjalan lebih cepat, terutama untuk tugas yang tidak memerlukan deteksi dengan akurasi tinggi.

Proses *YOLOv8* saat melatih model deteksi gambar dimulai dengan model memproses gambar melalui bagian pertama yang disebut *backbone*. Di sini, *YOLOv8* mengekstraksi fitur-fitur penting dari gambar, seperti bentuk dan pola, menggunakan arsitektur yang mirip dengan cara kerja jaringan saraf dalam. Setelah fitur-fitur penting ini diambil, mereka diproses lebih lanjut oleh bagian *neck* yang membantu memperkaya informasi, khususnya dalam memahami


objek pada berbagai ukuran dan posisi di gambar.

Setelah itu, bagian *head* dari *YOLOv8* memprediksi beberapa hal penting: pertama, ia menentukan lokasi objek dengan menggambar kotak (*bounding box*), lalu mengklasifikasikan jenis objek (misalnya, sel atau latar belakang), dan akhirnya memprediksi masker segmentasi yang menunjukkan area pasti di gambar yang merupakan objek. Selama proses pelatihan, model menghitung perbedaan antara prediksinya dan data asli (label) dari dataset. Berdasarkan perbedaan ini, model secara otomatis belajar untuk memperbaiki kesalahannya, sehingga pada setiap langkah pelatihan, model menjadi semakin baik dalam mengenali dan memprediksi objek dengan lebih akurat.

Proses ini berulang untuk setiap gambar dalam dataset selama jumlah *epoch* yang ditentukan, hingga model dilatih dengan baik untuk melakukan segmentasi yang tepat pada gambar baru.

3.5 Alur Program


pada penelitian ini Proses segmentasi untuk citra Imunohistokimia akan menggunakan model *Segment Anything Model* yang dikembangkan oleh META, untuk melakukan segmentasi ini peneliti menggunakan opsi koordinat *bounding box* sebagai input untuk model segmentasi. proses segmentasi akan dijelaskan dengan diagram balok dibawah ini:



Gambar 3.6: Alur Segmentasi

Pada blok diagram diatas dapat dilihat bahwa sebelum disegmentasi, citra *imunohistokimia* terlebih dahulu diproses oleh model objek deteksi untuk menentukan sel mana saja yang masuk dalam kategori sel aktif. Model objek deteksi ini nantinya akan menghasilkan output berupa koordinat dari *bounding box* setiap sel aktif, koordinat inilah yang nanti akan menjadi input untuk *Segment Anything Model* melakukan segmentasi. *Segment Anything Model* akan melakukan segmentasi berdasarkan koordinat yang didapat dari model objek deteksi tersebut.

3.6 Proses Segmentasi SAM



Gambar 3.7: Alur Segmentasi SAM

1. Image Encoder

gambar input diencoding menjadi embeddings hal ini memungkinkan gambar yang kompleks diubah menjadi bentuk yang dapat diolah oleh model neural.

2. Down Sample

langkah ini mengurangi resolusi dari fitur yang dihasilkan oleh Image Encoder. Down-sampling membantu dalam mengurangi beban komputasi dan mempertahankan fitur penting pada skala yang lebih kecil, membuat proses selanjutnya lebih efisien

3. **Prompt Encoder**

prompt encoder digunakan untuk mengolah masukan teks atau instruksi yang spesifik, yang mengarahkan proses dekoding.

4. **Lightweight Mask Decoder**

decoder ini bertugas membangun kembali informasi dari representasi fitur yang didown-sample dan informasi yang dihasilkan oleh prompt encoder menjadi masker yang valid. Masker ini digunakan untuk segmentasi, menunjukkan area tertentu dari citra asli berdasarkan karakteristik yang diidentifikasi melalui proses encoding dan sesuai dengan instruksi yang diberikan oleh prompt

5. **Valid Mask**

Output akhir dari proses ini adalah masker valid, yang bisa digunakan untuk tujuan seperti segmentasi objek, penyorotan area tertentu dalam citra, atau sebagai panduan untuk operasi pengolahan citra lebih lanjut.

[Halaman ini sengaja dikosongkan]

BAB IV










PENGUJIAN DAN ANALISIS


Pada penelitian ini dilakukan pengujian dan analisis terhadap hasil segmentasi dari Segment anything model dan gabungan dari model objek deteksi dengan SAM, analisis sebagai berikut

4.1 Pengujian Segment Anything model

Pada bagian ini dilakukan pengujian model Segment anything model terhadap citra dari dataset publik yang berasal dari *Kaggle*. Pengujian dilakukan dengan cara mengambil sampel yang belum pernah dilihat oleh model dan dibandingkan hasilnya dengan pendekatan Intersection Over Union menggunakan binary mask dari hasil segmentasi dengan binary mask ground truth. berikut adalah beberapa hasil segmentasi beserta hasil perhitungannya

Tabel 4.1: Perbandingan Gambar Asli, Hasil SAM, dan Ground Truth

Gambar Asli	Hasil SAM	Ground Truth
		
		
		
		



Dari beberapa hasil segmentasi diatas kita dapat melihat bahwa segment anything model sudah bisa melakukan segmentasi terhadap citra imunohistokimia, akan tetapi hasil segmentasi yang ada masih kurang akurat. Dapat dilihat bahwa model segment anything model memberikan mask tidak hanya pada bagian sel aktif melainkan memberi mask kepada bagian lain diantaranya sel yang tidak bereaksi dan area lemak.

Tabel 4.2: Hasil Pengukuran True Positive, False Positive, False Negative, True Negative, dan IoU Score

True Positive (TP)	False Positive (FP)	False Negative (FN)	True Negative (TN)	IoU Score
3354	404973	28	1245	0.008
14492	394993	0	115	0.035
7927	401535	56	82	0.019
8914	399805	0	881	0.022
18895	44535	9006	337164	0.261
259	409341	0	0	0.001
303	409297	0	0	0.001
28150	379591	9	1850	0.069
9233	32600	3435	364332	0.204
14518	107704	5873	281505	0.113
2876	74210	1472	331042	0.037
19992	385120	38	4450	0.049
17032	384067	2	8499	0.042
21584	385688	28	2300	0.053
18559	46112	5329	339600	0.265

Tabel 4.3: Hasil Rata-rata True Positive, False Positive, False Negative, True Negative, dan IoU Score

	Positif	Negatif
Positif	TP 12405.867	FN 1685.067
Negatif	FP 283971.400	TN 111537.667

$$\text{IoU} = 0.078658$$

Berdasarkan tabel di atas, performa *Segment Anything Model* (SAM) menunjukkan hasil yang sangat rendah dalam tugas segmentasi berdasarkan data confusion matrix dan perhitungan Intersection over Union (IoU). Nilai rata-rata True Positive (TP) sebesar 12.405,867 mengindikasikan bahwa model hanya mampu menangkap sebagian kecil dari kasus positif yang ada, sementara rata-rata False Positive (FP) yang sangat tinggi, yaitu 283.971,400, menunjukkan model sering salah mendeteksi kasus negatif sebagai positif. Selain itu, rata-rata True Negative (TN) sebesar 111.537,667 dan False Negative (FN) sebesar 1.685,067 memperlihatkan kelemahan model dalam mengenali data negatif dengan benar dan gagal mendeteksi sebagian kasus positif.














Nilai IoU rata-rata hanya mencapai 0,078658, yang jauh di bawah standar minimal 0,5 yang biasanya dianggap layak untuk tugas segmentasi. Dalam beberapa kasus, seperti pada data pertama dan kelima, nilai IoU bahkan hampir nol, menunjukkan prediksi model sangat tidak relevan dengan ground truth. Hal ini menandakan bahwa model memiliki tingkat kesalahan tinggi, baik dalam mendeteksi kasus positif maupun negatif. Rendahnya kinerja ini kemungkinan disebabkan oleh kualitas dataset pelatihan yang kurang representatif, parameter model yang belum optimal, atau potensi overfitting/underfitting pada model.

Untuk meningkatkan performa model, beberapa langkah dapat dilakukan, seperti memperbaiki kualitas dan keragaman dataset agar lebih representatif, melakukan fine-tuning hyperparameter model, serta menerapkan teknik post-processing seperti Non-Maximum Suppression (NMS) untuk mengurangi False Positive. Selain itu, evaluasi arsitektur model atau mencoba alternatif arsitektur segmentasi yang lebih sesuai dengan dataset dapat menjadi langkah strategis. Dengan perbaikan ini, diharapkan nilai IoU model dapat meningkat secara signifikan dan performa model menjadi lebih andal untuk tugas segmentasi yang diinginkan.

4.2 Pengujian Segment Anything Model Terhadap Citra Asli

Pada percobaan ini dilakukan percobaan terhadap *segment anything model* untuk segmentasi sel pada citra imunohistokimia yang diambil langsung dari preparat, berikut adalah hasil yang didapatkan:

Tabel 4.4: Perbandingan Gambar Asli, Hasil SAM, dan Ground Truth

Gambar Asli	Hasil SAM	Ground Truth
		
		
		
		
		
		

Dari tabel 4.4 diatas dapat dilihat bahwa *segment anything model* melakukan segmentasi ke seluruh objek pada citra imunohistokimia termasuk objek yang negatif, hal ini terjadi karena *segment anything model* dirancang untuk melakukan segmentasi ke semua objek apabila tidak diberikan petunjuk. Hal ini dapat dibuktikan dengan melihat *binary mask* pada tabel 4.7 diatas berwarna putih dan dibawah ini adalah perhitungan dengan menggunakan *confusion matrix* dan pendekatan *intersection over union*

Tabel 4.5: Data Pengukuran TP, FP, FN, TN, dan IoU Score Model SAM pada citra asli

True Positive (TP)	False Positive (FP)	False Negative (FN)	True Negative (TN)	IoU Score
0	406601	0	2999	0.000
0	406462	0	3138	0.000
23776	382732	11	3081	0.058
8496	398052	163	2889	0.021
6673	399920	60	2947	0.016
4538	402019	3	3040	0.011
3501	403279	1	2819	0.009
0	406284	0	3316	0.000
6871	400426	0	2303	0.017
28306	378240	60	2994	0.069
35844	370879	34	2843	0.088
2904	403952	0	2744	0.007

Tabel 4.6: Data Rata-rata TP, FP, FN, TN, dan IoU Score Model SAM pada citra asli

	Positif	Negatif
Positif	TP 10075.750	FN 27.667
Negatif	FP 396570.500	TN 2926.083


$$\text{IoU} = 0.025$$

Berdasarkan Tabel 4.5, terlihat bahwa pada beberapa pengujian, nilai TP sangat rendah atau bahkan nol, menunjukkan model tidak mampu mendeteksi objek yang benar dalam citra. Sebaliknya nilai FP sangat tinggi yang mengindikasikan bahwa model sering salah mendeteksi area yang seharusnya tidak termasuk dalam kelas target, hal ini terjadi karena *segment anything model* akan melakukan segmentasi ke semua objek yang ada pada citra imunohistokimia tanpa terkecuali. Nilai FN rendah, tetapi hal ini tidak cukup signifikan untuk meningkatkan performa keseluruhan karena IoU score tetap rendah, dengan sebagian besar nilai mendekati nol. TN menunjukkan model mampu mengenali area non-target dengan baik, meskipun tidak secara konsisten.

Rata-rata performa model yang ditampilkan dalam Tabel 4.6 mempertegas kelemahan model dalam mendeteksi area target, dengan rata-rata TP hanya 10.075,75, sementara FP mencapai 396.570,50. Tingginya jumlah FP dibandingkan TP menyebabkan nilai IoU score rendah, yang mengindikasikan bahwa segmentasi oleh SAM tidak akurat pada citra asli. Hasil ini menyoroti kebutuhan untuk melakukan penyempurnaan pada model atau metode preprocessing data untuk meningkatkan performa deteksi dan segmentasi.

4.3 Kurva ROC Segment Anything Model


Selanjutnya pada penelitian ini dilakukan pengukuran dengan menggunakan *Receiver Operating Characteristic* dengan tujuan untuk mengevaluasi kinerja model klasifikasi. ROC digunakan untuk menganalisis kemampuan model dalam membedakan antara kelas positif dan negatif dengan melihat trade-off antara True Positive Rate (TPR) dan False Positive Rate (FPR) pada berbagai ambang keputusan. Nilai AUC (Area Under the Curve) pada ROC memberikan gambaran seberapa baik model dapat memprediksi kelas positif dan negatif secara keseluruhan. Pengukuran ini efektif pada data dengan distribusi kelas yang seimbang karena memberikan evaluasi kinerja menyeluruh.



Gambar 4.1: Kurva ROC *Segment Anything Model*


Kurva ROC diatas memiliki nilai AUC sebesar 0.90, yang mengindikasikan performa model segmentasi yang sangat baik. Nilai AUC ini berada jauh di atas baseline acak (AUC = 0.5), menunjukkan bahwa model memiliki kemampuan tinggi dalam membedakan area positif dan negatif pada citra imunohistokimia. Bentuk kurva yang cepat meningkat pada tingkat false positive rate (FPR) rendah mengindikasikan bahwa model dapat mendeteksi area positif dengan akurasi tinggi tanpa menghasilkan terlalu banyak kesalahan positif. Hal ini mencerminkan keandalan model dalam menghasilkan confidence score yang berkorelasi kuat dengan ground truth.

Kurva yang meningkat juga diakibatkan karena *segment anything model* adalah model yang bersifat universal sehingga model tersebut akan melakukan segmentasi terhadap semua objek yang ada dalam citra yang diproses dan hal tersebut yang membuat hasil dari IoU dan ROC sangat berbeda karena pada pengujian IoU dilakukan dengan menggunakan ground truth yang hanya berisi sel aktif sedangkan *segment anything model* melakukan segmentasi pada semua objek pada gambar.




Gambar 4.2: Hasil segmentasi pada *segment anything model*

Untuk mengatasi hal tersebut ada beberapa cara yang dapat dilakukan salah satunya adalah dengan menggunakan grind yang membagi gambar menjadi beberapa bagian sehingga model akan melakukan deteksi dalam area kecil dan ada kemungkinan hasil akan lebih akurat jika hanya ingin mendeteksi sel aktif, tapi cara ini masih kurang efektif karena *segment anything model* juga melakukan segmentasi pada kotak yang tidak ada isinya. berikut adalah salah satu hasil segmentasi yang memanfaatkan grind.




Gambar 4.3: Hasil segmentasi menggunakan grind pada *segment anything model*

Pada bagian ini juga dilakukan pengukuran ROC untuk segmentasi yang memanfaatkan grind dengan tujuan untuk melihat seberapa besar nilai *confidence score* yang dihasilkan oleh *segment anything model*, grind diatur dengan nilai 100 lalu overlap 10 untuk menghindari area kosong antar grind dan hasilnya adalah berikut ini.




Gambar 4.4: Kurva ROC *Segment Anything Model* dengan Grind

Dari kurva diatas dapat dilihat bahwa AUC hanya bernilai 0.22, ini menandakan bahwa peforma model buruk yang dapat disebabkan oleh proses segmentasi yang berulang-ulang untuk tiap bagian grind yang ada dan membuat model tidak yakin terhadap objek yang ada pada bagian kosong. Selanjutnya dilakukan percobaan dengan mengubah nilai dari grind menjadi 280 dari yang awalnya 100 dan didapatkan hasil sebagai berikut.



Gambar 4.5: Hasil segmentasi menggunakan grind dengan nilai 280 pada *segment anything model*




Gambar 4.6: Kurva ROC *Segment Anything Model* dengan Grind 280

Curve yang dihasilkan menunjukkan performa model klasifikasi berdasarkan hubungan antara True Positive Rate (TPR) dan False Positive Rate (FPR) pada berbagai threshold. Dari grafik, nilai AUC (Area Under the Curve) yang mendekati 1 menunjukkan bahwa model memiliki kemampuan yang sangat baik untuk membedakan antara kelas positif dan negatif.

Secara keseluruhan, bentuk kurva dan nilai AUC yang tinggi mengindikasikan bahwa model ini efektif dan dapat diandalkan dalam klasifikasi, terutama pada dataset ini. Namun, performa spesifiknya dapat bervariasi tergantung pada cara penggunaan dan nilai grind yang dipakai.

4.4 Analisis Peforma Model YOLOv8

Setelah dilakukan *training* didapatkan hasil peforma sebagai berikut ini



Gambar 4.7: Peforma Model YOLOv8

Grafik di atas menunjukkan performa model selama pelatihan dan validasi berdasarkan berbagai matriks. Pada grafik train/box_loss dan val/box_loss terlihat bahwa bounding box loss

menurun secara konsisten selama pelatihan, mengindikasikan bahwa model semakin baik dalam memprediksi bounding box. Namun, pada data validasi terdapat fluktuasi yang menunjukkan tantangan dalam generalisasi model terhadap data yang belum dilihat sebelumnya. Hal serupa terlihat pada `train/seg_loss` dan `val/seg_loss`, di mana segmentation loss untuk pelatihan menurun secara stabil, tetapi validasi loss menunjukkan fluktuasi yang signifikan. Hal ini mungkin mengindikasikan perlunya peningkatan kualitas dataset atau penerapan teknik regularization tambahan untuk meningkatkan kemampuan generalisasi model. Sementara itu, `train/cls_loss` dan `val/cls_loss` memperlihatkan penurunan yang stabil selama pelatihan, namun fluktuasi pada validasi loss kembali menandakan adanya ketidaksesuaian antara data pelatihan dan validasi, yang dapat diperbaiki dengan upaya lebih lanjut dalam preprocessing data atau dataset balancing.

Pada grafik `train/df_l_loss` dan `val/df_l_loss`, distribution focal loss menurun dengan baik selama pelatihan. Meskipun validasi loss menunjukkan beberapa ketidakstabilan, tren secara keseluruhan tetap menurun, yang mengindikasikan peningkatan kemampuan model. Metrik evaluasi seperti `metrics/precision(B)` dan `metrics/recall(B)` menunjukkan performa yang baik dalam prediksi bounding box, dengan precision mendekati 0,9 dan recall mendekati 1. Hal ini menandakan kemampuan model untuk mendeteksi objek dengan tingkat positif palsu yang rendah. Hal serupa juga terlihat pada `metrics/precision(M)` dan `metrics/recall(M)` untuk segmentasi, di mana precision tetap stabil di sekitar 0,9, sedangkan recall sedikit lebih fluktuatif namun tetap mendekati angka optimal.

Pada grafik `metrics/mAP50(B)` dan `metrics/mAP50(M)`, mean average precision pada IoU threshold 0.5 menunjukkan performa yang sangat baik dengan nilai mendekati 0.9 atau lebih. Ini mengindikasikan prediksi yang akurat pada toleransi overlap yang lebih longgar. Namun, pada `metrics/mAP50-95(B)` dan `metrics/mAP50-95(M)` performa sedikit menurun dengan nilai mendekati 0,6-0,7, yang menunjukkan tantangan model dalam mencapai prediksi akurat pada toleransi IoU yang lebih ketat. Secara keseluruhan, model menunjukkan tren peningkatan selama pelatihan, dengan performa yang baik pada precision dan recall. Namun, fluktuasi pada data validasi menandakan perlunya perbaikan untuk meningkatkan stabilitas dan generalisasi model, terutama pada tugas segmentasi dan toleransi IoU yang lebih tinggi.














Secara umum, grafik menunjukkan bahwa model belajar dengan baik selama proses pelatihan, dengan tren penurunan loss yang konsisten dan peningkatan metrik evaluasi seperti precision, recall, dan mAP. Namun ada fluktuasi pada data validasi terutama pada `seg_loss` dan `cls_loss` menunjukkan adanya potensi overfitting atau masalah dengan generalisasi. Model menunjukkan performa yang baik pada IoU threshold rendah (0.5) tetapi masih memiliki ruang untuk peningkatan pada IoU yang lebih tinggi (0.5-0.95). Langkah-langkah seperti peningkatan kualitas dataset atau tuning hyperparameter dapat membantu meningkatkan stabilitas performa pada validasi.


4.5 Pengujian Model Deteksi Objek Yang Digabungkan Dengan Segment Anything Model

Pada bagian ini dilakukan pengujian pada *segmnet anything model* yang digabungkan dengan model deteksi objek YOLOv8, dengan cara menggunakan output yang berupa koordinat dari model deteksi objek sebagai input *segment anything model* untuk melakukan segmentasi. Pengujian ini dilakukan dengan menggunakan sampel citra imunohistokimia tipe Ki67 dari dataset publik yang berasal dari *kaggle*, citra yang diambil adalah citra yang belum pernah dili-

hat oleh model dan hasil segmentasinya akan dibandingkan dengan ground truth dengan menggunakan pendekatan confusion matriks dan perhitungan *Intersection over union*. Di bawah ini adalah beberapa hasil segmentasi menggunakan model YOLOv8 dan *segment anything model*

Tabel 4.7: Perbandingan Gambar Asli, Hasil YOLO+SAM, dan Ground Truth

Gambar Asli	Hasil YOLO+SAM	Ground Truth
		
		
		
		
		
		



Dari tabel di atas dapat dilihat bahwa hasil segmentasi yang dihasilkan oleh *segment anything model* yang dibantu oleh model YOLOv8 menghasilkan hasil yang lebih akurat jika dibandingkan dengan hasil menggunakan *segment anything model* saja. Hasil tersebut bisa dibuktikan dengan tabel Pengukuran TP, FP, FN, TN, dan IoU di bawah ini

Tabel 4.8: Data Pengukuran TP, FP, FN, TN, dan IoU Score Model YoloSAM

True Positive (TP)	False Positive (FP)	False Negative (FN)	True Negative (TN)	IoU Score
2539	939	843	405279	0.588
12930	7321	1562	387787	0.593
7245	3274	738	398343	0.644
7690	5188	1224	395498	0.545
15527	8592	12374	373107	0.425
0	0	259	409341	0.000
0	0	303	409297	0.000
24474	12988	3685	368453	0.595
10652	3720	2016	393212	0.650
16841	4494	3550	384715	0.677
3550	1661	798	403591	0.591
15941	6248	4089	383322	0.607
14578	5485	2456	387081	0.647
17410	11037	4202	376951	0.533
21417	15406	2471	370306	0.545

Tabel 4.9: Data Rata-rata TP, FP, FN, TN, dan IoU Score Model YoloSAM

	Positif	Negatif
Positif	TP 11386.267	FN 2704.667
Negatif	FP 5756.867	TN 389752.200

$$\text{IoU} = 0.509290$$

Berdasarkan data pada Tabel 4.8 dan Tabel 4.9, performa model YoloSAM menunjukkan kemampuan yang cukup baik dalam mendeteksi sel aktif pada citra imunohistokimia jika dibandingkan dengan hasil *segment anything model*, meskipun masih terdapat beberapa kelemahan. Nilai rata-rata True Positive (TP) sebesar 11.386,267 mengindikasikan bahwa model mampu mendeteksi sebagian besar sel aktif. Namun, adanya rata-rata False Positive (FP) sebesar 5.756.867 dan False Negative (FN) sebesar 2.704.667 menunjukkan bahwa model masih sering salah mendeteksi area non-sel aktif sebagai sel aktif, serta melewatkan beberapa sel aktif yang ada. Sementara itu, nilai True Negative (TN) yang tinggi, yaitu 389.752.200, mengindikasikan bahwa model memiliki akurasi yang baik dalam mengidentifikasi area non-sel aktif.






Nilai *Intersection over Union* (IoU) rata-rata yang dicapai adalah 0.509290, dengan nilai IoU pada setiap data berkisar antara 0.425 hingga 0.671. Hal ini menunjukkan bahwa tingkat tumpang tindih antara prediksi model dengan label sebenarnya masih tergolong sedang, sehingga model masih perlu ditingkatkan performanya. Tantangan utama terlihat pada beberapa kasus dengan nilai FN dan FP yang tinggi, serta nilai IoU yang rendah, seperti pada baris kelima di mana TP adalah nol, menandakan kegagalan model dalam mendeteksi sel aktif pada kondisi tertentu.


Secara keseluruhan, model memiliki potensi yang baik, tetapi masih perlu dioptimalkan, terutama untuk mengurangi nilai FP dan FN agar performa deteksi lebih akurat. Beberapa langkah yang direkomendasikan adalah penerapan augmentasi data untuk meningkatkan generalisasi model, penyesuaian parameter seperti confidence threshold dan NMS (Non-Maximum Suppression) untuk meminimalkan kesalahan deteksi, serta mempertimbangkan metode post-processing atau penggunaan model ensemble untuk meningkatkan nilai IoU. Dengan perbaikan ini, diharapkan model mampu memberikan hasil yang lebih presisi dan andal untuk aplikasi segmentasi sel imunohistokimia.

4.6 Pengujian Model Gabungan Terhadap Citra Asli

Pada pengujian ini dilakukan percobaan terhadap model gabungan antara *segment anything model* dengan model deteksi objek YOLOv8 untuk segmentasi sel pada citra imunohistokimia yang diambil langsung dari preparat, berikut adalah hasil yang didapatkan:

Tabel 4.10: Perbandingan Gambar Asli, Hasil SAM, dan Ground Truth

Gambar Asli	Hasil SAM	Ground Truth
		
		



Dari tabel 4.10 diatas dapat dilihat bahwa model bisa melakukan segmentasi tapi dengan akurasi yang sangat rendah, hal ini dapat dibuktikan dengan melihat *binary mask* pada tabel 4.10 yang mana terlihat tidak sesuai dengan ground truth yang ada, selain itu terdapat perhitungan mengguankan *confusion matrix* dan *intersection over union* seperti dibawah ini.

Tabel 4.11: Data Pengukuran TP, FP, FN, TN, dan IoU Score Model YoloSAM pada citra asli

True Positive (TP)	False Positive (FP)	False Negative (FN)	True Negative (TN)	IoU Score
0	0	0	409600	0.000
0	0	0	409600	0.000
912	221	22875	385592	0.038
0	0	8659	400941	0.000
0	0	6733	402867	0.000
0	0	4541	405059	0.000
0	0	3502	406098	0.000
0	0	0	409600	0.000
0	0	6871	402729	0.000
10181	2920	18185	378314	0.825
3591	207	32287	373515	0.999
0	395	2904	406301	0.000

Tabel 4.12: Data Rata-rata TP, FP, FN, TN, dan IoU Score Model YoloSAM pada citra asli

	Positif	Negatif
Positif	TP 1223.667	FN 8879.750
Negatif	FP 311.917	TN 399184.667


$$\text{IoU} = 0.0386$$

Hasil pengujian model YoloSAM terhadap citra asli menunjukkan bahwa performa model masih memerlukan perbaikan, terutama dalam mendeteksi objek positif. Berdasarkan Tabel 4.11, nilai True Positive (TP) masih sangat rendah untuk sebagian besar data, sementara False Negative (FN) memiliki nilai yang sangat tinggi, menunjukkan bahwa model sering gagal mendeteksi keberadaan objek pada citra. Sebaliknya, nilai False Positive (FP) relatif rendah, yang mengindikasikan bahwa model jarang memberikan deteksi palsu, dan True Negative (TN) konsisten sangat tinggi, menunjukkan kemampuan model yang baik dalam mengenali area negatif. IoU Score juga bervariasi, dengan beberapa citra memiliki skor mendekati 1, menandakan prediksi yang akurat, namun sebagian besar lainnya memiliki skor 0, yang berarti model gagal memberikan prediksi yang relevan pada citra tersebut.

Dari Tabel 4.11, rata-rata pengukuran mengonfirmasi kelemahan model dalam mendeteksi objek positif, dengan TP rata-rata hanya 1223,667 dan FN rata-rata sangat tinggi sebesar 8879,750. Sementara itu, rata-rata FP yang rendah, yaitu 311,917, menunjukkan bahwa prediksi positif palsu relatif jarang terjadi. Rata-rata TN yang sangat tinggi, sebesar 399184,667, menunjukkan bahwa model sangat baik dalam mengenali area negatif. Secara keseluruhan, rendahnya IoU Score pada sebagian besar data menunjukkan bahwa model belum optimal dalam menghasilkan bounding box yang sesuai dengan ground truth.

Hasil ini menunjukkan bahwa meskipun model dapat mengenali area negatif dengan baik, kemampuannya dalam mendeteksi objek positif masih lemah. Untuk meningkatkan performa, diperlukan strategi seperti menambah data training dengan anotasi yang lebih baik, menggunakan augmentasi data yang lebih variatif, atau melakukan penyesuaian threshold deteksi dan hyperparameter. Hal ini diharapkan dapat meningkatkan akurasi prediksi, mengurangi FN, dan meningkatkan rata-rata IoU Score pada model.

4.7 Analisis Peforma Model YOLOv8 Setelah Fine-tuning



Gambar 4.8: Peforma Model YOLOv8 Setelah Fine-tuning

Hasil training fine-tuning menunjukkan tren yang positif, ditandai dengan penurunan konsisten pada semua jenis loss, baik untuk training maupun validation. Grafik train/box_loss, train/seg_loss, train/cls_loss, dan train/dfl_loss menampilkan penurunan signifikan terutama pada awal training, yang mengindikasikan bahwa model berhasil belajar dengan baik. Hal serupa juga terlihat pada val/box_loss, val/seg_loss, val/cls_loss, dan val/dfl_loss, yang menurun dengan pola serupa, menunjukkan bahwa model memiliki kemampuan generalisasi yang baik tanpa indikasi overfitting.











Selain itu, matriks evaluasi seperti precision, recall, dan mAP juga menunjukkan peningkatan yang signifikan. Precision dan recall untuk bounding box (metrics/precision(B) dan metrics/recall(B)) serta segmen (metrics/precision(M) dan metrics/recall(M)) konsisten meningkat hingga mencapai nilai sekitar 0.8. Mean Average Precision (mAP) juga menunjukkan hasil yang baik, dengan mAP50 untuk bounding box dan segmen mencapai nilai tinggi (0.8), sementara mAP50-95 berada pada kisaran 0.6 yang wajar mengingat tantangan pada berbagai tingkat IOU.

Secara keseluruhan, hasil ini menunjukkan bahwa model berhasil dilatih dengan baik dan menunjukkan performa yang solid. Untuk peningkatan lebih lanjut, Anda dapat mempertimbangkan augmentasi data tambahan atau mengoptimalkan hyperparameter untuk mencapai mAP yang lebih tinggi, terutama pada mAP50-95.

4.8 Pengujian Model Gabungan Terhadap Citra Asli setelah Fine-Tuning

Pada tahap ini dilakukan pengujian untuk model deteksi objek YOLOv8 yang telah melalui proses fine-Tuning terhadap citra imunohistokimia yang secara langsung diambil dari preparat. Citra yang digunakan pada pengujian ini adalah citra yang belum pernah dilihat oleh model pada saat training dan untuk perhitungan menggunakan *confusion matrix* yang nantinya nilai dari matriks tersebut akan dihitung dengan pendekatan *Intersection over union*. Berikut ini adalah hasil dari pengujian serta perhitungan :

Tabel 4.13: Perbandingan Gambar Asli, Hasil SAM, dan Ground Truth

Gambar Asli	Hasil SAM	Ground Truth
		
		
		
		
		
		

Dari tabel 4.13 diatas, dapat dilihat bahwa model yang sudah difine-tuning memiliki akurasi yang lebih tinggi dalam mendeteksi sel aktif untuk dilakukan segmentasi, sebagai pendukung telah dilakukan perhitungan dengan menggunakan *confusion matrix* dan *intersection over union* untuk mengukur akurasi dengan menggunakan ground truth dari citra imunohistokimia yang belum pernah dilihat oleh model

Tabel 4.14: Data Pengukuran TP, FP, FN, TN, dan IoU Score Model YoloSAM Setelah Fine-Tuning

True Positive (TP)	False Positive (FP)	False Negative (FN)	True Negative (TN)	IoU Score
15537	5551	8250	380262	0.530
7717	3680	942	397261	0.625
5687	2716	1046	400151	0.602
4001	7221	540	397838	0.340
3269	3290	233	402808	0.481
4809	5008	2062	397721	0.405
23595	7654	4771	373580	0.655
22110	3421	13768	370301	0.563

Tabel 4.15: Data Rata-rata TP, FP, FN, TN, dan IoU Score Model YoloSAM Setelah Fine-Tuning

	Positif	Negatif
Positif	TP 10840.625	FN 3951.500
Negatif	FP 4817.625	TN 389990.250

$$\text{IoU} = 0.525$$

Dari tabel 4.12 dapat dilihat rata-rata TP setelah fine-tuning adalah 10.840.625, yang jauh lebih tinggi dibandingkan hasil sebelumnya. Ini menunjukkan bahwa model semakin mampu mendeteksi area target dengan benar. Nilai FP juga menurun menjadi rata-rata 4.817,625, mencerminkan pengurangan kesalahan dalam mendeteksi area non-target. FN tetap berada pada nilai rata-rata 3.951,500, menunjukkan peningkatan kemampuan model untuk mengurangi jumlah area target yang terlewat. Selain itu, TN memiliki rata-rata sangat tinggi, yaitu 389.990,250, yang menunjukkan bahwa model tetap andal dalam mengenali area non-target.

Nilai rata-rata IoU mencapai 0,525, meningkat signifikan dibandingkan sebelumnya. Hal ini menunjukkan bahwa prediksi segmentasi model menjadi lebih akurat setelah fine-tuning. Secara keseluruhan, fine-tuning memberikan dampak positif terhadap kinerja model YoloSAM dalam mendeteksi dan menyegmentasi area target pada citra asli. Ini menunjukkan bahwa penyesuaian parameter dan pelatihan tambahan dapat secara efektif meningkatkan performa model.

4.9 Analisis perbandingan penggunaan SAM dan YoloSAM

Pada penelitian ini dilakukan juga perbandingan performa, *resource* yang dibutuhkan antara SAM dan YoloSAM yang, jika kita melihat hasil perhitungan pada pengujian SAM dan

YoloSAM pada subbab 4.1, 4.2, 4.5, 4.6 dan 4.8 maka dapat dilihat bahwa performa YoloSAM lebih unggul daripada SAM dalam hal melakukan segmentasi pada sel aktif yang spesifik. Hal ini dapat dibuktikan dengan nilai ROC YoloSAM yang berada diatas 0.5 sedangkan untuk SAM ada dibawah 0.5, hal tersebut terjadi karena pengujian dilakukan untuk melakukan segmentasi yang spesifik pada sel aktif yang mana akan lebih akurat jika dilakukan oleh model YoloSAM. Dilain sisi SAM juga memiliki performa yang cukup baik dalam melakukan segmentasi pada semua objek yang ada pada citra, hal ini bisa dibuktikan dengan pengujian pada subbab 4.3 yang mana dilakukan pengujian terhadap SAM untuk melakukan segmentasi untuk semua objek dan dilakukan pengukuran menggunakan *Receiver Operating Characteristic* dan didapatkan nilai AUC sebesar 0.90. Tapi hasil tersebut juga dipengaruhi oleh cara penggunaan model SAM, ketika dilakukan pengujian terhadap model SAM menggunakan grind nilai AUC berubah tergantung ukuran grind yang digunakan seperti yang bisa dilihat pada gambar 4.4 dan gambar 4.6.

Selanjutnya dilakukan perbandingan waktu yang diperlukan untuk melakukan segmentasi antara menggunakan model SAM dan model YoloSAM. Data perbandingan akan diambil dari hasil pengujian melakukan segmentasi dengan 18 gambar menggunakan model SAM dan model YoloSAM. dan didapatkan hasil seperti berikut.

Gambar	Waktu (detik)	Gambar	Waktu (detik)
1.png	6.74	2.png	7.44
3.png	6.80	4.png	6.34
5.png	6.96	6.png	6.81
7.png	7.23	8.png	6.83
9.png	6.37	10.png	6.90
11.png	6.82	12.png	6.98
13.png	6.60	14.png	7.09
15.png	7.05	16.png	6.47
17.png	6.22	18.png	6.63

Tabel 4.16: Waktu proses segmentasi menggunakan SAM

Dari tabel diatas dapat dilihat bahwa SAM membutuhkan waktu rata-rata 6.79 detik untuk melakukan segmentasi pada 18 gambar input dan membutuhkan 8 detik untuk load model, selanjutnya adalah hasil waktu untuk YoloSAM.

Gambar	Waktu (detik)	Gambar	Waktu (detik)
1.png	5.06	2.png	4.87
3.png	4.28	4.png	4.54
5.png	3.70	6.png	4.30
7.png	2.59	8.png	2.71
9.png	2.79	10.png	6.56
11.png	5.18	12.png	4.41
13.png	5.55	14.png	4.44
15.png	5.34	16.png	4.79
17.png	5.92	18.png	5.07

Tabel 4.17: Waktu proses segmentasi menggunakan YoloSAM

Dari tabel diatas dapat dilihat bahwa SAM membutuhkan waktu rata-rata 4.56 detik untuk melakukan segmentasi pada 18 gambar input dan membutuhkan waktu 18 detik untuk load model. hal ini terjadi karena ada dua model yang di load yaitu model SAM dan YOLOv8. Jika kita membandingkan waktu segmentasi dari SAM dan YoloSAM, YoloSAM terlihat lebih cepat dalam melakukan segmentasi karena objek yang disegmentasi hanya berdasarkan input koordinat dari model YOLOv8. Berbeda dengan SAM yang melakukan segmentasi secara menyeluruh pada gambar.

BAB V

PENUTUP

5.1 Kesimpulan

Berdasarkan hasil pengujian yang telah dilakukan pada penelitian ini dapat ditarik beberapa kesimpulan sebagai berikut:

1. Hasil segmentasi menggunakan *segment anything model* sangat bergantung pada cara model tersebut digunakan, hal ini dapat dilihat ketika menggunakan model secara langsung nilai AUC mencapai 0.90 sementara saat menggunakan grind dengan nilai 100 AUC hanya bernilai 0.22 dan saat grind diatur menjadi 280 nilai AUC menjadi 0.65
2. Berdasarkan hasil pengujian, model YoloSAM lebih baik dalam melakukan segmentasi pada sel aktif jika dibandingkan dengan model SAM. Hal ini dibuktikan dengan nilai IoU YoloSAM pada tabel 4.15 dengan nilai 0.525 yang lebih tinggi jika dibandingkan dengan nilai IoU SAM pada tabel 4.6 yang bernilai 0.025.
3. Berdasarkan Analisa pada subbab 4.9 dapat dilihat bahwa model YoloSAM melakukan segmentasi dengan rata-rata waktu 4.56 detik yang lebih cepat jika dibandingkan dengan model SAM yang memerlukan waktu rata-rata 6.79 detik. Hal ini terjadi karena YoloSAM hanya mensegmentasi berdasarkan input koordinat dari model YOLOv8. Berbeda dengan SAM yang melakukan segmentasi secara menyeluruh pada gambar. Jadi lama waktu segmentasi bagi YoloSAM juga dipengaruhi oleh banyaknya objek yang dideteksi oleh YOLOv8 pada suatu gambar

5.2 Saran

Untuk pengembangan lebih lanjut pada penelitian berikutnya adalah antara lain:

1. Penelitian diharapkan menggunakan struktur selain YOLOv8 untuk mengetahui performa *segment anything model* dalam menerima input dari model lain
2. Tipe citra Imunohistokimia menggunakan ER, Her2 dan PR
3. Versi model *segment anything model* yang digunakan adalah *segment anything model 2*

[Halaman ini sengaja dikosongkan]

DAFTAR PUSTAKA

- [1] K. Z. Mao, P. Zhao, and P. H. Tan, "Supervised learning-based cell image segmentation for p53 immunohistochemistry," *IEEE Transactions on Biomedical Engineering*, vol. 53, no. 6, pp. 1153–1163, 2006.
- [2] A. Dewanto *et al.*, "Semi-automated and manual methods for counting cells expressing p75 receptor in endometriotic lesions," in *2018 4th International Conference on Science and Technology (ICST)*, IEEE, 2018.
- [3] M. Sezgin and B. Sankur, "Survey over image thresholding techniques and quantitative performance evaluation," *Pattern Recognition*, vol. 34, no. 4, pp. 711–725, 2004.
- [4] J. F. Canny, "A computational approach to edge detection," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 8, no. 6, pp. 679–698, 1986.
- [5] R. Adams and L. Bischof, "Seeded region growing," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 16, no. 6, pp. 641–647, 1994.
- [6] P. F. O. Ronneberger and T. Brox, "U-net: Convolutional networks for biomedical image segmentation," *Medical Image Computing and Computer-Assisted Intervention (MICCAI)*, pp. 234–241, 2015.
- [7] A. Dosovitskiy *et al.*, "An image is worth 16x16 words: Transformers for image recognition at scale," *arXiv preprint arXiv:2010.11929*, 2020.
- [8] H. Touvron, M. Cord, M. Douze, F. Massa, A. Sablayrolles, and H. Jégou, "Training data-efficient image transformers & distillation through attention," in *Proceedings of the International Conference on Machine Learning (ICML)*, 2021.
- [9] A. Kirillov *et al.*, *Segment anything: Foundations, prompts, and the broad applicability of a visual prompting paradigm*, <https://arxiv.org/abs/2304.02643v1>, Meta AI Research, FAIR, 2023. Accessed: Apr. 6, 2023.
- [10] A. H. Coons, H. J. Creech, and R. N. Jones, "Immunological properties of an antibody prepared against pneumococcal polysaccharide type iii," *Journal of Experimental Medicine*, vol. 82, no. 6, pp. 409–417, 1941. doi: 10.1084/jem.82.6.409.
- [11] J. A. Ramos, "Technical aspects of immunohistochemistry," *Veterinary Pathology*, vol. 45, no. 4, pp. 405–426, 2008. doi: 10.1354/vp.45-4-405.
- [12] D. R. T.O. Nielsen S.C.Y. Leung, "Assessment of ki67 in breast cancer: Updated recommendations from the international ki67 in breast cancer working group," *Journal of the National Cancer Institute*, pp. 808–819, 2021.
- [13] F. D. S. Chiloiro A. Bianchi, "Radically resected pituitary adenomas: Prognostic role of ki 67 labeling index in a monocentric retrospective series and literature review," *Pituitary*, pp. 267–276, 2014.
- [14] A. Z. M. Everingham L. Van Gool and J. Winn, "The pascal visual object classes challenge," *International Journal of Computer Vision*, vol. 88, pp. 303–338, 2010.

- [15] T.-Y. Lin *et al.*, “Microsoft coco: Common objects in context,” *European Conference on Computer Vision (ECCV)*, pp. 740–755, 2014. doi: 10.1007/978-3-319-10602-1_48.
- [16] D. Papadopoulos, J. Barros, and P. Konstantinidis, “A survey on evaluation metrics for object detection: Performance measures, challenges and new insights,” *IEEE Access*, vol. 5, pp. 7343–7357, 2017. doi: 10.1109/ACCESS.2017.2697427.
- [17] A. A. Taha and A. Hanbury, “Metrics for evaluating 3d tumor segmentation: Analysis of masked and non-masked approaches,” *Medical Image Analysis*, vol. 24, no. 1, pp. 7–16, 2015. doi: 10.1016/j.media.2015.05.001.
- [18] T. Sorensen, “A method of estimating the distribution of an area,” *Dansk Botanisk Arkiv*, vol. 15, pp. 1–34, 1948.
- [19] Y. B. I. Goodfellow and A. Courville, “Deep learning,” *MIT Press*, pp. 1–775, 2016.
- [20] B. D. J. Carlson and J. Carlson, “Roboflow: The end-to-end computer vision pipeline,” *Roboflow Blog*, 2023. [Online]. Available: <https://blog.roboflow.com>.
- [21] S. Russell and P. Norvig, “Artificial intelligence: A modern approach,” 2015.
- [22] S. Ren, K. He, R. B. Girshick, and J. Sun, “Faster r-cnn: Towards real-time object detection with region proposal networks,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 39, no. 6, pp. 1137–1149, 2015. doi: 10.1109/TPAMI.2016.2577031.
- [23] B. D. J. Carlson and J. Carlson, “Efficient labeling techniques for computer vision tasks,” *Roboflow Blog*, 2023. [Online]. Available: <https://blog.roboflow.com/efficient-labeling-techniques>.
- [24] F. M. A. Paszke S. Gross, “Pytorch: An imperative style, high-performance deep learning library,” *Advances in Neural Information Processing Systems*, pp. 8024–8035, 2019.
- [25] T. Fawcett, “An introduction to roc analysis,” *Pattern Recognition Letters*, vol. 27, pp. 861–874, 2006.
- [26] J. Davis and M. Goadrich, “The relationship between precision-recall and roc curves,” *Proceedings of the 23rd International Conference on Machine Learning (ICML)*, pp. 233–240, 2006.

BIOGRAFI PENULIS




Novriyanto Putra Satir, lahir pada 30 November 2002 di desa Tutuyan, Sulawesi utara. Penulis merupakan anak pertama dari pasangan suami istri, Ramjito dan Sundari. penulis telah menempuh pendidikan formal yaitu TK Fatmawati Tutuyan, SD Negeri 1 Tutuyan 3, SMP Negeri 2 Tutuyan, dan SMA Negeri 1 Tutuyan. Setelah lulus dari SMA Negeri 1 Tutuyan pada tahun 2020, Penulis mendaftar dan diterima di Departemen Teknik Komputer FTEIC pada tahun 2020 dan terdaftar dengan NRP 5024201001. Selama masa perkuliahan penulis memiliki berbagai pengalaman dalam bidang desain grafik. Penulis pernah menjadi staff desain dokumentasi multimedia pada kegiatan MAGE 7 pada tahun 2021 dan MAGE 8 pada tahun 2022 yang bertugas untuk membuat seluruh desain kegiatan. Selain itu penulis juga pernah menjabat sebagai staff divisi relasi dan komunikasi di HIMATEKKOM ITS pada tahun 2022 dan dilanjutkan menjadi ketua divisi komunikasi dan informasi di HIMATEKKOM ITS pada tahun 2023. Penulis juga pernah berpartisipasi menjadi asisten praktikum pada kegiatan praktikum pemrograman lanjutan Teknik Komputer ITS pada tahun 2023. Hal yang sangat disyukuri oleh penulis adalah ITS sebagai kampus perkuliahan sangat mendukung potensi mahasiswa, baik secara akademik maupun manajerial ataupun non akademik lainnya. Penulis merasakan adanya perubahan drastis dalam pribadinya, pelatihan percaya diri, pelibatan dengan kegiatan sosial, dan penajaman keahlian. Apabila pembaca ingin menyampaikan kritik dan saran kepada penulis mengenai Tugas Akhir ini, dapat menghubungi melalui email novriyanto-putrasatir@gmail.com.

[Halaman ini sengaja dikosongkan]

LAMPIRAN













5.3 Gambar Citra imunohistokimia Dari Kaggle

Tabel 5.1: Gambar Citra imunohistokimia Dari Kaggle
Gambar Citra IHC dari Kaggle




5.4 Gambar Citra imunohistokimia Dari Universitas Airlanga

Tabel 5.2: Gambar Citra imunohistokimia Dari Universitas Airlanga
Gambar Citra IHC dari Universitas Airlanga


5.5 Gambar pengambilan sampel dari preparat Universitas Airlanga



Gambar 5.1: Proses Pengambilan Citra


5.6 Hasil Segmentasi Citra IHC dari Universitas Airlangga Menggunakan Segment Anything Model


Tabel 5.3: Hasil segmentasi citra IHC dari Universitas Airlangga Menggunakan SAM



5.7 Hasil Segmentasi Citra IHC Kaggle Menggunakan Segment Anything Model







Tabel 5.4: Hasil segmentasi citra IHC dari Kaggle Menggunakan SAM






5.8 Hasil Segmentasi Dengan YOLOv8 dan Segment Anything Model Setelah Fine-Tuning

Tabel 5.5: Hasil segmentasi citra IHC dari Kaggle Menggunakan SAM

Hasil segmentasi menggunakan SAM		
		
		



[Halaman ini sengaja dikosongkan]